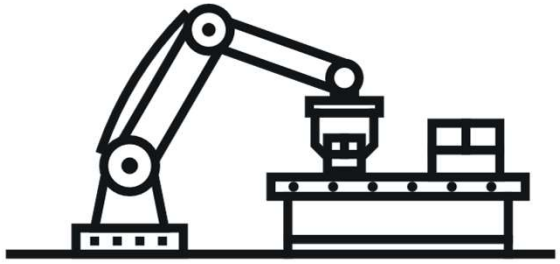
STU FEI
SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

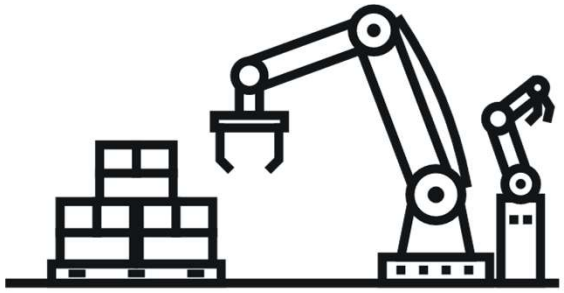
DEFECTBENCH

OD ZÁKLADNEJ CNN K POZORNOSTI A TRANSFORMEROM

Čo mal každý doplnok k CNN priniesť, ako sa trénoval a čo ukazujú namerané výsledky



Detekcia povrchových defektov · NEU-DET · GC10-DET · Magnetic Tile — 3 trénovacie seedy (17, 42, 73), testovacia časť, priemer ± smer. odch.



PREHĽAD

Jedna základná CNN na úlohu, potom vždy jeden doplnok

Detekčná vetva — ohraničujúce boxy na NEU-DET, GC10-DET, Magnetic Tile

1 · Faster R-CNN
ResNet-50 + FPN, predtrénovaný na COCO

→

2 · + CBAM
pozornosť na úrovniach FPN P2–P5

Segmentačná vetva — pixelové masky na Magnetic Tile (jediný dataset so skutočnými maskami)

3 · U-Net
Enkodér ResNet-34, od nuly

→

4 · + ImageNet
predtrénované váhy enkodéra

→

5 · + brány
brány pozornosti, od nuly

→

6 · + transformer
TransUNet, R50 + ViT-B/16

Ďalšie detektory — rovnaké dáta a seedy, porovnané s Faster R-CNN (1)

A · RT-DETRv2-S
R18-vd + hybridný enkodér

B · DINO
Swin-T, 900 dopytov

C · RF-DETR
N / S, chrbtica DINOv2

D · YOLO12
N / S, oblastná pozornosť

Férové referencie: 2 vs 1 · 4 vs 3 · 5 vs 3 (oba bez predtrénovania) · 6 vs 4 (oba predtrénované) · A–D vs 1

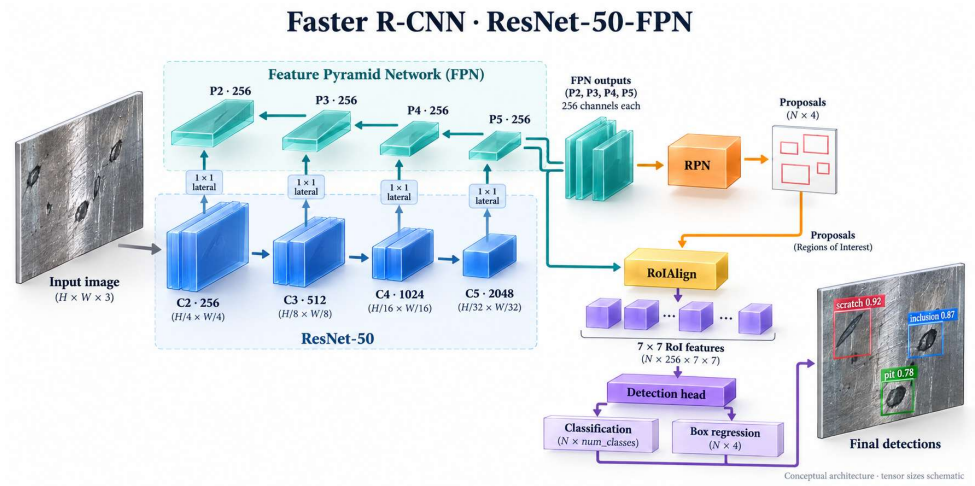
Pôvodný DETR a YOLOv11 v projekte nie sú — namiesto nich RF-DETR a YOLO12 · Swin-Unet nie je rozšírením CNN, preto tu nie je

DETEKCIA · 1 / 6

ZÁKLADNÝ CNN DETEKTOR

Faster R-CNN · ResNet-50 + FPN, predtrénovaný na COCO

Faster R-CNN s ResNet-50-FPN backbone



Popis siete

- Konvolučná chrbtica ResNet-50 extrahuje príznaky
- FPN ich spojí do máp P2–P6 (kroky 4–64)
- RPN navrhuje oblasti, RoI hlavy klasifikujú a spresňujú boxy
- implementácia z torchvision, inicializovaná z COCO (box AP 37.0)

Očakávanie

- Spoľahlivá, dobre známa dvojstupňová referencia
- FPN by mala pomôcť defektom veľmi rôznych veľkostí
- Predtrénovanie na COCO by malo vyvážiť malé datasety (936–1692 trénovacích obrázkov)
- Slabé miesto: žiadny mechanizmus, ktorý by odlíšil textúru defektu od textúry pozadia

configs/models/_frcnn_base.yaml · faster_rcnn_r50_fpn

41.3 M parametrov, SGD s efektívnou dávkou 8

41.32 M

parametrov celkom (hlava NEU); 41.10 M trénovateľných

800 / 1333

vstup: kratšia / dlhšia strana, px

res3–res5

trénovateľné stupne chrbtice (3 vrstvy)

Hyperparameter	Nastavenie
Optimalizátor	SGD, lr 0.01, momentum 0.9, weight decay 1e-4
Dávka	4 na krok × 2 akumulácie = 8
Rozvrh LR	300 iterácií warmup, ×0.1 pri 67 % a 89 % trénovania
Epochy	max. 36; včasné zastavenie, patience 8 na val COCO AP
Presnosť výpočtov	AMP fp16
Augmentácia	horizontálne/vertikálne preklopenie 0.5; jas a kontrast ±0.2
Inferencia	skóre ≥ 0.001, max. 100 boxov, NMS IoU 0.5
Vstupné kanály	šedotón replikovaný do RGB

Seedy 17, 42, 73 · celkový počet parametrov sa mierne líši podľa počtu tried: GC10 41.35 M, Magnetic Tile 41.32 M

1 · ZÁKLADNÝ CNN DETEKTOR — VÝSLEDKY TRÉNOVANIA

Najlepší na NEU, najslabší na Magnetic Tile

Testovacia časť	AP	AP50	AP75	AR100	Recall@wp	F1@wp
NEU-DET	0.388 ± 0.006	0.766	0.345	0.566	0.713	0.726
GC10-DET	0.274 ± 0.008	0.554	0.245	0.456	0.585	0.636
Magnetic Tile	0.214 ± 0.017	0.423	0.188	0.372	0.285	0.392

Najlepšia epocha (z max. 36)
NEU 11–15 · GC10 14–27 · MT 11–30

Čas trénovania
NEU 2486 s · GC10 5296 s · MT 12774 s

Latencia, medián end-to-end
NEU 62 · GC10 97 · MT 72 ms

Priemer z 3 seedov · wp = pracovný bod pri IoU 0.5, prah skóre zvolený na validácii · boxy MT sú odvodené z masiek · RTX A6000, dávka 1

1 · ZÁKLADNÝ CNN DETEKTOR — ČO FUNGOVALO A PREČO

Veľké defekty nájde, slabé prehliadne

Silné triedy (priemerné AP)

- NEU: patches 0.57, scratches 0.50
- GC10: crescent gap 0.57, welding line 0.56, punching hole 0.49
- MT: uneven 0.42, blowhole 0.37

Slabé triedy (priemerné AP)

- NEU: crazing 0.14, rolled-in scale 0.24
- GC10: inclusion 0.08, crease 0.11, rolled pit 0.12
- MT: crack 0.07, break 0.10

Prečo

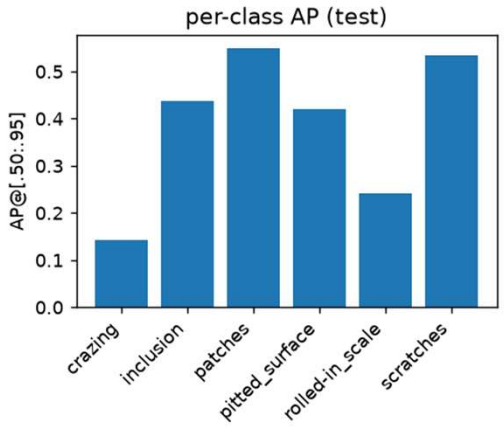
AP50 je na každom datasete zhruba dvojnásobok AP75: defekt sa väčšinou nájde, ale jeho box je nepresný — slabé, textúrové defekty nemajú ostré hrany. Na Magnetic Tile sú boxy odvodené z masiek a recall v pracovnom bode je len 0.285. Práve túto medzeru má zaplniť modul pozornosti.

AP podľa tried, priemer cez seedy 17, 42, 73 (runs/*/faster_rcnn_r50_fpn/bbox/seed*/eval/metrics.json)

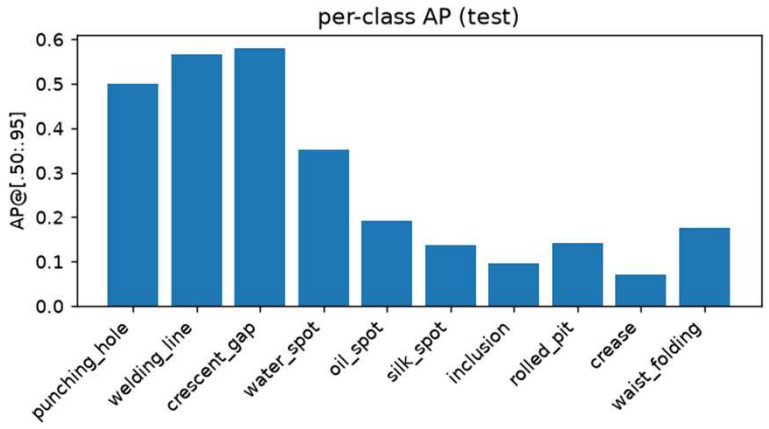
1 · ZÁKLADNÝ CNN DETEKTOR — AP PODĽA TRIED

Crazing, inclusion a crack sú na chvoste

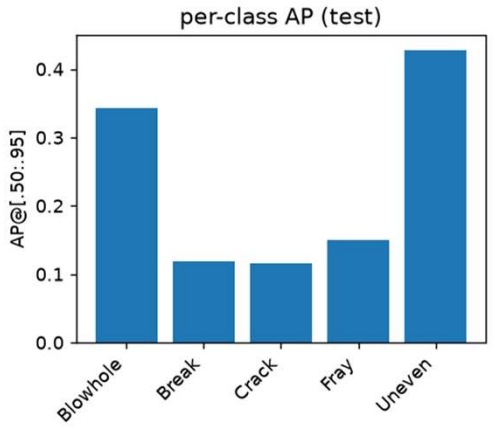
NEU-DET



GC10-DET



Magnetic Tile

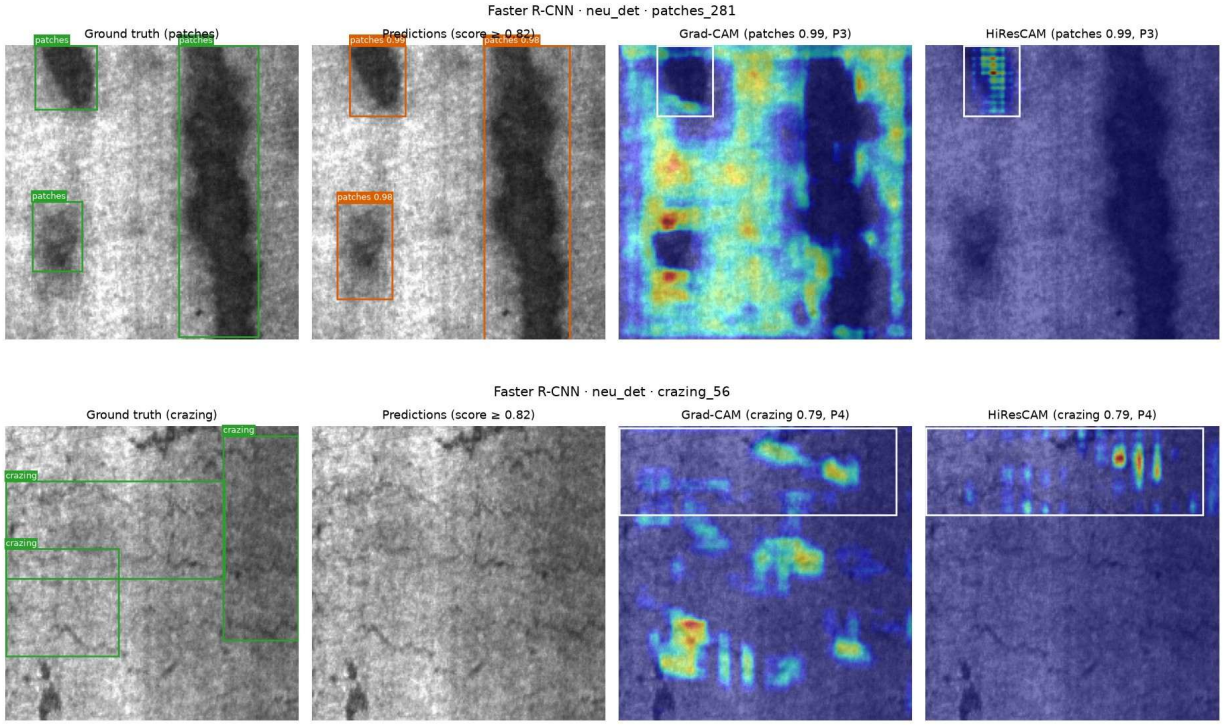


Slabé triedy sú tie nevýrazné, textúrové: crazing (NEU), inclusion a crease (GC10), crack a break (Magnetic Tile).

Seed 42, testovacia časť · figures/per_model/1_faster_rcnn_r50_fpn/<dataset>_seed42_per_class_ap.png

1 · ZÁKLADNÝ CNN DETEKTOR — GRAD-CAM

Kam sa detektor pozerá: patches vs. crazing



Ako čítať mapy

- Patches (AP 0.57): nájdené všetky tri boxy; odozva HiResCAM zostáva vnútri tmavej škvrny
- Crazing (AP 0.14): žiadny box neprejde prahom 0.82; najlepší (0.79) pokrýva GT box len čiastočne
- Odozva pri crazing je rad malých bodov pozdĺž línií trhlín, bez jasnej hrany, o ktorú by sa box oprel

Checkpoint so seedom 42, testovacie obrázky (príklad s mediánovou plochou pre každú triedu) · gradcam/1_faster_rcnn_r50_fpn/neu_det

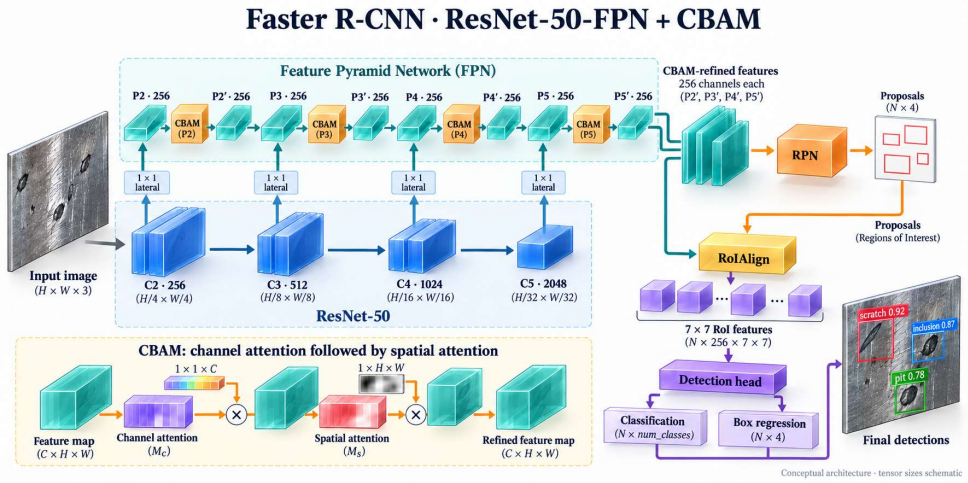
DETEKCIA · 2 / 6

+ POZORNOSŤ CBAM

Kanálová a priestorová pozornosť na úrovniach FPN P2–P5

2 · + POZORNOSŤ CBAM — MYŠLIENKA

CBAM na každej úrovni FPN P2–P5



Čo sa pridáva

- Kanálová brána: avg + max pooling → zdieľaný MLP → na ktorých kanáloch záleží
- Priestorová brána: konvolúcia 7×7 → kam v mape sa pozerať
- Umiestnená za výstupnými konvolúciami FPN, takže RPN a RoI hlavy vidia zjemnené mapy; P6 sa prepočíta zo zjemnenej P5
- Oficiálny kód CBAM (Woo et al., ECCV 2018)

Očakávané zlepšenia

- Potlačiť textúru pozadia, zvýrazniť oblasti defektov
- Lepšia lokalizácia (vyššie AP75) pri slabých, nízkokontrastných defektoch
- Menej falošne pozitívnych → vyššia precision
- Takmer zadarmo: +0.08 % parametrov

defectbench/models/cbam.py · configs/models/faster_rcnn_r50_fpn_cbam.yaml

2 · + POZORNOSŤ CBAM — PARAMETRE A HYPERPARAMETRE

+34 256 parametrov, nič iné sa nezmenilo

41.36 M

parametrov celkom (hlava NEU), vs 41.32 M

4 × CBAM

jeden na úroveň P2, P3, P4, P5 (kroky 4–32), bez zdieľania váh

Nastavenie CBAM	Hodnota
Kanály brány	256 (šírka FPN)
Redukčný pomer	16
Pooling kanálov	priemer + max
Priestorová brána	konvolúcia 7×7 + BatchNorm
P6 (iba RPN)	max_pool2d(refined P5, 1, 2)
Inicializácia	CBAM: predvolené v PyTorch · zvyšok: COCO
Postup trénovania	rovnaký ako referencia: SGD 0.01, dávka 8, 36 epoch, včasné zastavenie 8, AMP

runs/neu_det/faster_rcnn_r50_fpn_cbam/bbox/seed42/params.json · 41 359 042 celkom, 41 136 642 trénovateľných

2 · + POZORNOSŤ CBAM — VÝSLEDKY TRÉNOVANIA

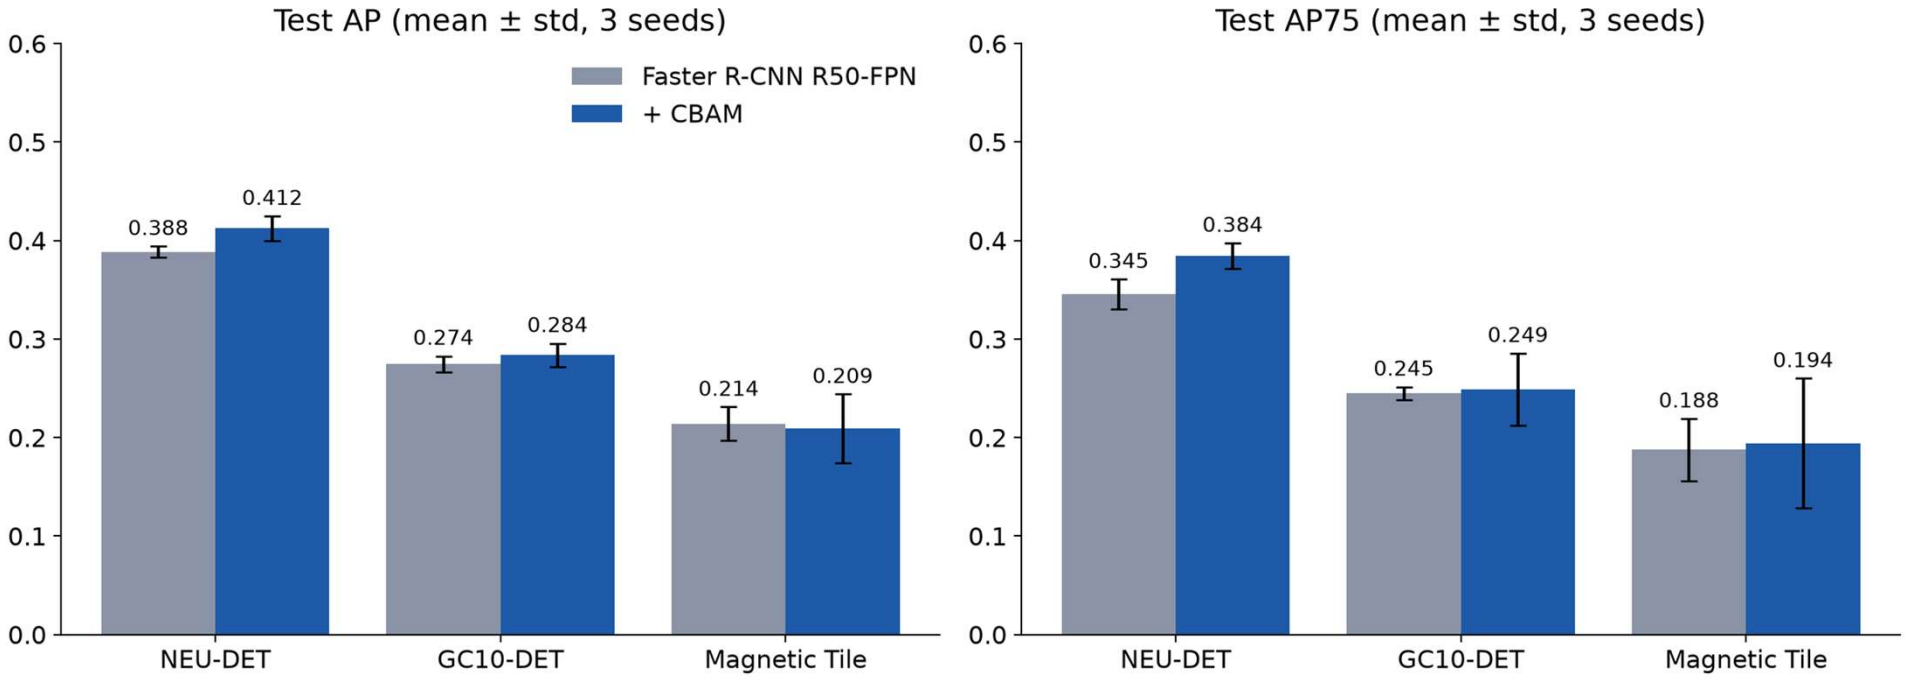
Jasný zisk na NEU, malý na GC10, žiadny na MT

Dataset	Metrika (test)	Referencia	+ CBAM	Zmena
NEU-DET	AP	0.388 ± 0.006	0.412 ± 0.012	+0.024
NEU-DET	AP75	0.345	0.384	+0.039
NEU-DET	Precision@wp	0.741	0.801	+0.060
GC10-DET	AP	0.274 ± 0.008	0.284 ± 0.012	+0.009
GC10-DET	F1@wp	0.636	0.666	+0.030
Magnetic Tile	AP	0.214 ± 0.017	0.209 ± 0.035	−0.005
Magnetic Tile	Recall@wp	0.285	0.333	+0.048
Magnetic Tile	AUROC (obrázky)	0.910	0.886	−0.024

Náklady: latencia e2e NEU 62 → 65 ms, GC10 97 → 108 ms · čas trénovania NEU 2486 → 3585 s · najlepšia epocha NEU 10–26, GC10 10–34, MT 14–15

Priemer ± smer. odch. cez seedy 17, 42, 73 · RTX A6000, dávka 1 · latencia MT (72 → 51 ms) a čas trénovania sa medzi behmi líšia príliš na porovnanie

Iba zisk na NEU-DET je väčší ako rozptyl seedov



figures/comparison/detection_frcnn_vs_cbam.png · priemer ± smer. odch. cez seedy 17, 42, 73 · chybová úsečka = 1 smer. odch.

CBAM pomáha tam, kde je problémom textúra

Lepšie

- NEU: všetkých 6 tried hore — scratches 0.50 → 0.55, pitted 0.43 → 0.47, rolled-in 0.24 → 0.27
- Najviac získa AP75 na NEU (+0.039): boxy sedia tesnejšie
- GC10: oil spot 0.18 → 0.21, inclusion 0.08 → 0.09

Nie lepšie

- Zisk AP na GC10 (+0.009) je v rámci jednej smerodajnej odchýlky
- MT: AP bez zmeny, AUROC obrázkov nižšie, rozptyl seedov dvojnásobný (0.017 → 0.035)
- Pomalší: latencia +4 % (NEU) až +12 % (GC10)

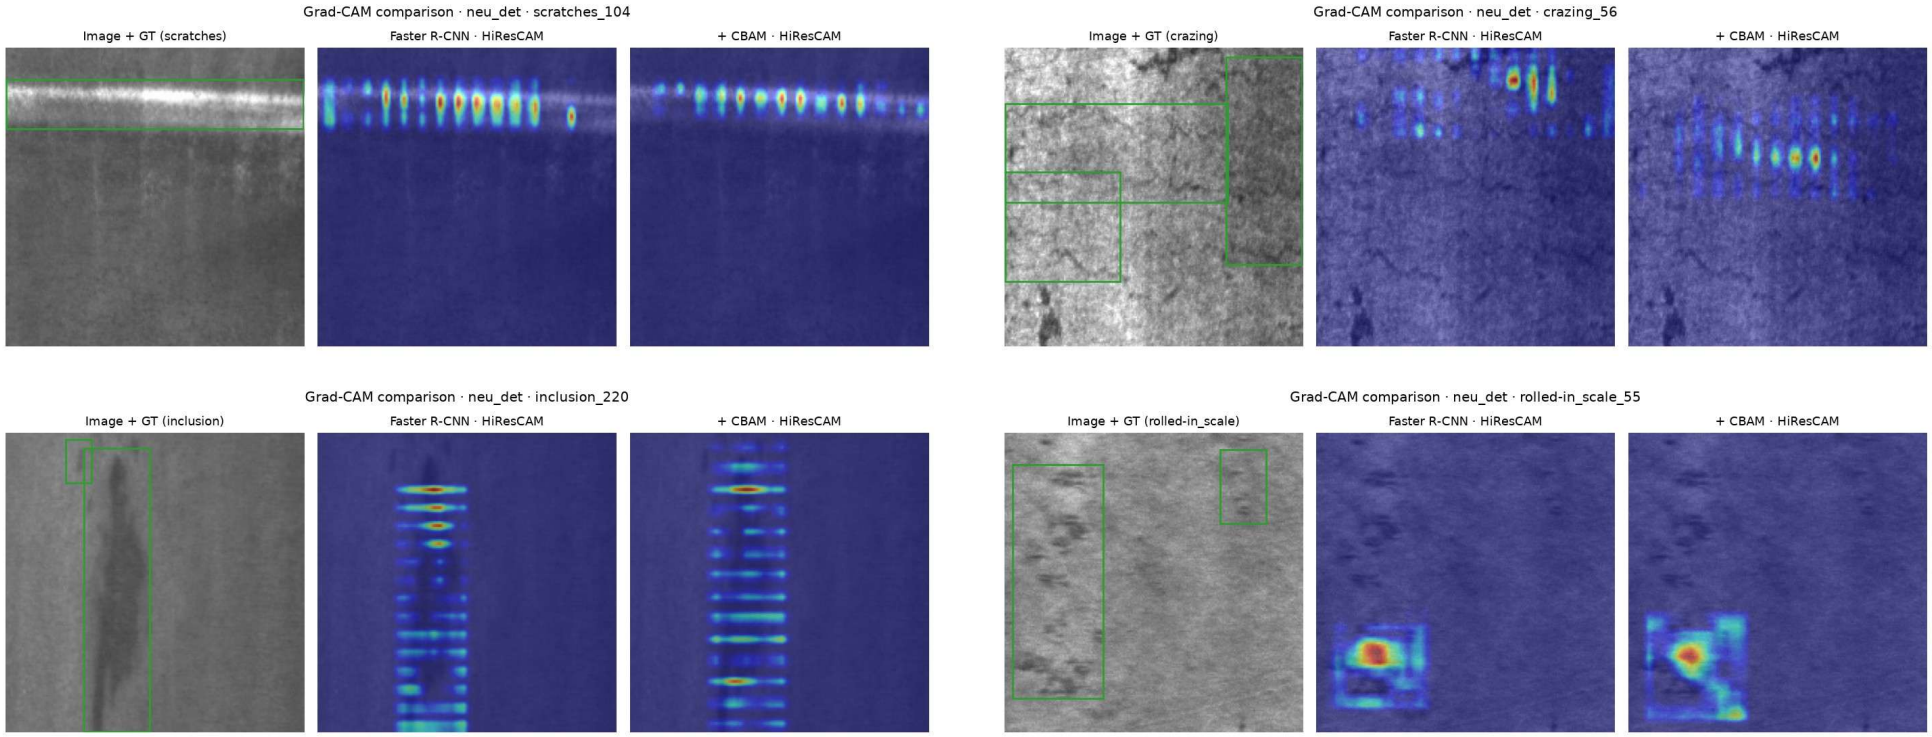
Prečo

Brány prevažujú kanály a pozície na mapách, ktoré vstupujú do RPN a RoI hláv; na NEU, kde defekt aj pozadie sú oceľová textúra, to zostrí lokalizáciu. Na MT je chybných iba 268 trénovacích obrázkov a boxy pochádzajú z masiek — pozornosť nevyrieši vzácnu a zašumenú supervíziu.

AP podľa tried: priemer cez seedy · trénovacia časť MT 936 obrázkov, z toho 668 normálnych

2 · + POZORNOSŤ CBAM — GRAD-CAM

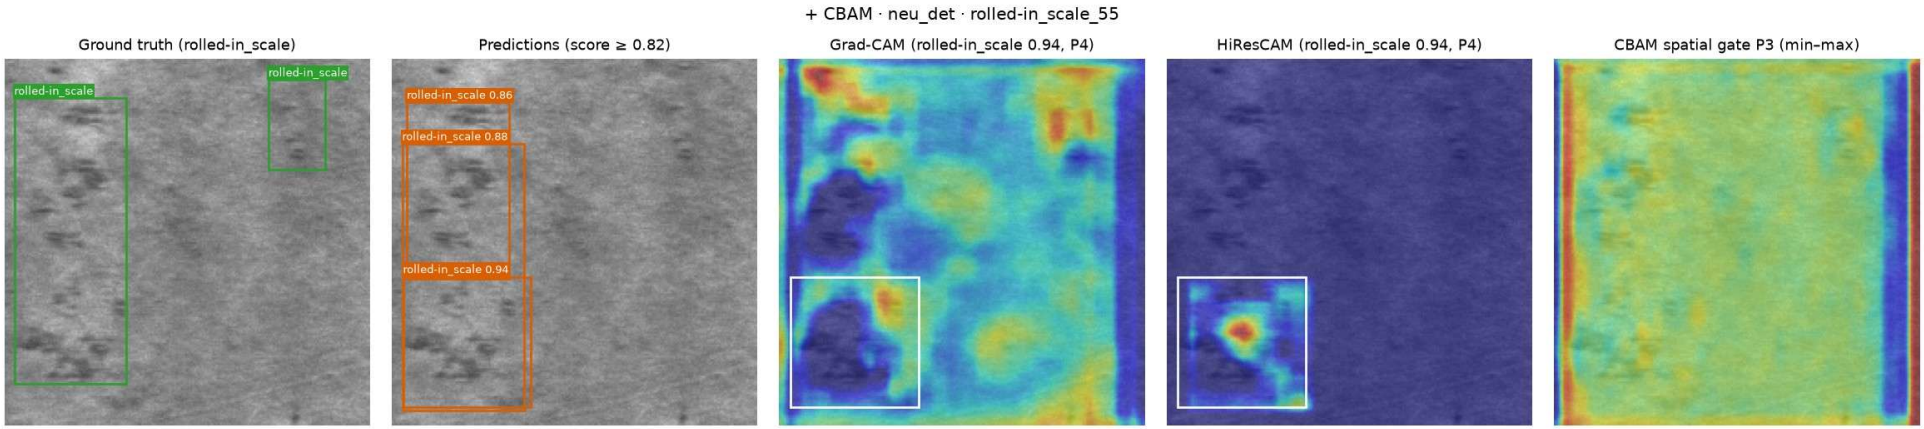
Rovnaké obrázky: CBAM rozloží odozvu pozdĺž defektu



HiResCAM pre najlepší box triedy z anotácie · seed 42 · gradcam/comparison/neu_det · jednotlivé príklady, samy osebe nie sú dôkazom

2 · + POZORNOSŤ CBAM — SAMOTNÁ BRÁNA

Brána CBAM prevažuje jemne, nič nemaskuje



Čo brána robí

Nad oceľou takmer rovná: mierne preváženie, nie maska defektu. HiResCAM stále sedí na tmavých šupinách v boxe.

Čítajte opatrne

Svetlý rám na okraji pochádza z nulového paddingu v konvolúcii 7×7, nie z naučeného zamerania.

gradcam/2_faster_rcnn_r50_fpn_cbam/neu_det/rolled-in_scale_rolled-in_scale_55.png · seed 42

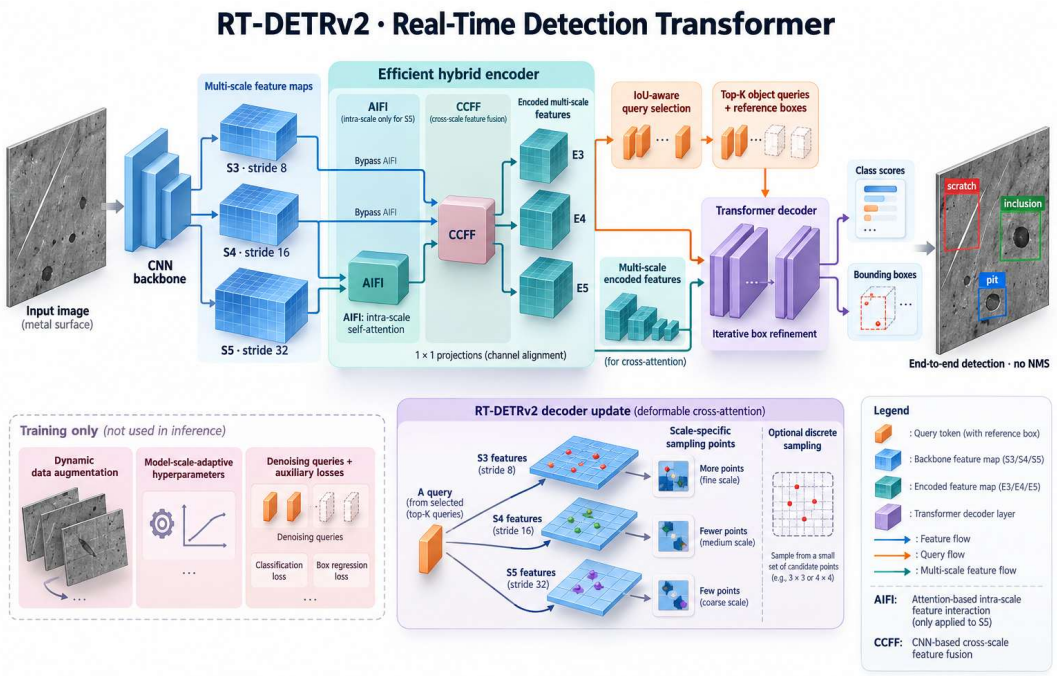
ĎALŠIE DETEKTORY · A / D

RÝCHLY TRANSFORMER

RT-DETRv2-S · ResNet-18-vd + hybridný enkodér, predtrénovaný na COCO

A · RÝCHLY TRANSFORMER — MYŠLIENKA

RT-DETRv2: CNN chrbtica, pozornosť tam, kde je lacná



Popis siete

- Chrbtica ResNet-18-vd (CNN) dáva príznaky na troch mierkach
- Hybridný enkodér: self-attention len na najhrubšej mape, fúziu mierok robia konvolúcie
- Dekodér s 300 dopytmi priamo predikuje množinu boxov — bez kotiev, bez NMS
- Oficiálny kód lyuwenyu/RT-DETR, recept r18vd 120e, COCO checkpoint 48.1 AP

Očakávanie

- Globálny kontext by mal oddeliť defekt od textúry pozadia
- Spresňovanie boxov vo vrstvách dekodéra → vyššie AP75
- Polovica parametrov Faster R-CNN a vstup 640 px → oveľa nižšia latencia
- Riziko: DETR modely potrebujú veľa dát a dlhší tréning

configs/rtdetrv2_s.yaml · configs/resolved/rtdetrv2_s_framework_config.yml · Lv et al., 2024

20.1 M parametrov, AdamW a oficiálny recept

20.09 M

parametrov celkom (hlava NEU) — polovica Faster R-CNN

640 px

štvorcový vstup, menší než 800 / 1333

5.7 GB

špičková pamäť GPU pri tréningu (NEU)

Hyperparameter	Nastavenie
Predtrénovanie	oficiálny RT-DETRv2-S COCO checkpoint (48.1 AP)
Optimalizátor	AdamW, lr 1e-4, weight decay 1e-4 (0 na norm. vrstvách)
Dávka	16 — ako v recepte, lr bez škálovania
Rozvrh LR	warmup 2000 iterácií
Epochy	max. 120; augmentácie sa vypnú v epoche 117
Včasné zastavenie	patience 15 na val COCO AP
Presnosť výpočtov	AMP
Augmentácia	oficiálny recept RT-DETRv2
Inferencia	skóre ≥ 0.001, max. 100 boxov, bez NMS

configs/resolved/rtdetrv2_s_framework_batch_lr_scaling.json: použitý optimalizátor = optimalizátor receptu · seedy 17, 42, 73

A · RÝCHLY TRANSFORMER — VÝSLEDKY TRÉNOVANIA

Vyššie AP na všetkých troch datasetoch

Testovacia časť	AP	AP50	AP75	AR100	Recall@wp	F1@wp
NEU-DET	0.457 ± 0.003	0.767	0.475	0.710	0.696	0.737
GC10-DET	0.324 ± 0.004	0.615	0.295	0.560	0.611	0.684
Magnetic Tile	0.323 ± 0.026	0.528	0.338	0.647	0.251	0.377

Δ AP oproti Faster R-CNN
NEU +0.068 · GC10 +0.050 · MT +0.109

Čas trénovania
NEU 61 · GC10 79 · MT 41 min

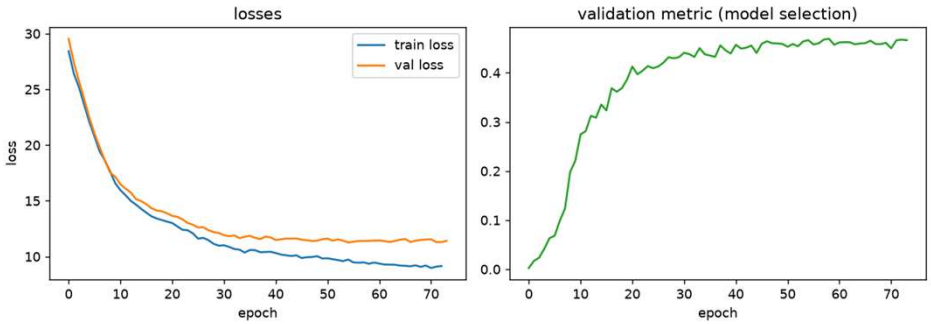
Latencia, medián end-to-end
NEU 14 · GC10 24 · MT 18 ms

Priemer ± smer. odch. cez seedy 17, 42, 73 · wp = pracovný bod pri IoU 0.5, prah skóre zvolený na validácii · boxy MT sú odvodené z masiek · RTX A6000, dávka 1

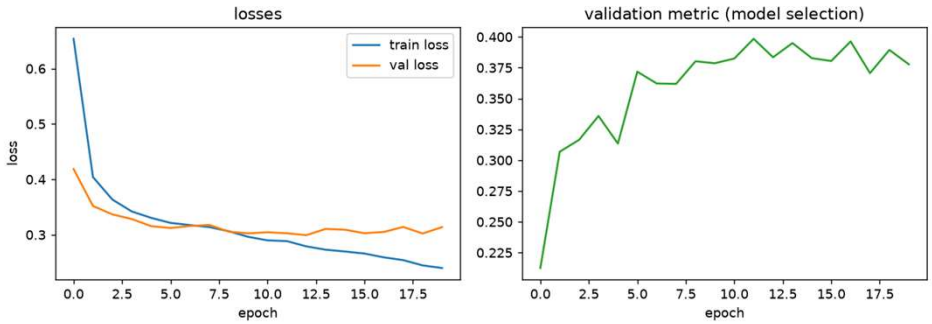
A · RÝCHLY TRANSFORMER — KRIVKY TRÉNOVANIA

Val AP rastie pomaly, plató až okolo epochy 45

RT-DETRv2-S



Faster R-CNN (referencia)



RT-DETRv2 potrebuje približne 45 epoch, kým sa val AP ustáli okolo 0.46; včasné zastavenie ho ukončí okolo epochy 73 (z max. 120). Faster R-CNN je na vrchole už okolo epochy 11. DETR sa musí najprv naučiť priraďovať dopyty k objektom, a to trvá dlhšie.

Seed 42, NEU-DET · validačná metrika = val COCO AP (výber modelu) · figures/per_model/2_rtdetrv2_s, 1_faster_rcnn_r50_fpn

A · RÝCHLY TRANSFORMER — ČO BOLO LEPŠIE A PREČO

Presnejšie boxy pri 4× nižšej latencii

Lepšie

- AP +0.05 až +0.11 na všetkých datasetoch; malý rozptyl seedov (NEU ± 0.003)
- AP75 na NEU 0.345 → 0.475: boxy sedia tesnejšie
- GC10: crease 0.11 → 0.30, waist folding 0.17 → 0.35; MT fray 0.12 → 0.44
- Latencia na NEU 62 → 14 ms pri polovičnom počte parametrov

Horšie

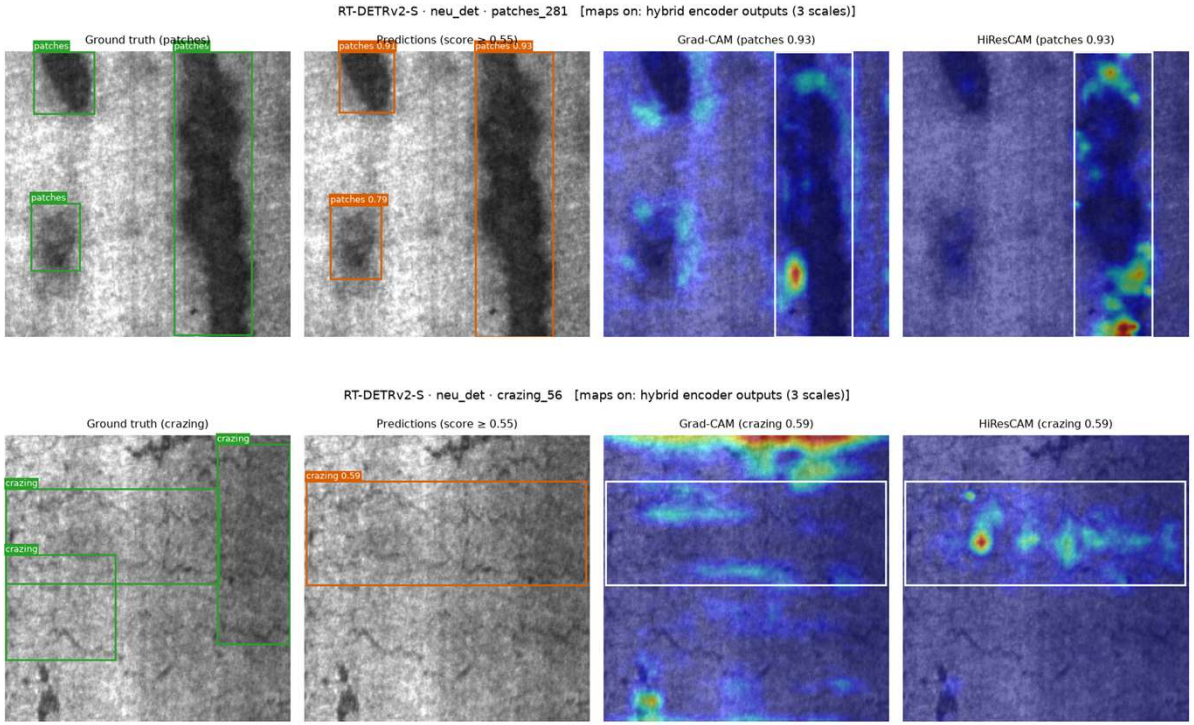
- MT: recall v pracovnom bode 0.251, F1 0.377 (referencia 0.392)
- GC10 rolled pit 0.12 → 0.05
- Dlhší tréning na NEU: 41 → 61 min

Pravdepodobne prečo (interpretácia)

Dekodér spresňuje každý box v niekoľkých vrstvách a tréning jedna-k-jednej trestá duplicitné a nepresné boxy — to sedí so skokom v AP75. Pozornosť len na hrubej mape drží latenciu nízko. Na MT model defekty nájde (AR100 0.647, najvyššie zo všetkých), ale s nízkym skóre, takže prah z validácie veľkú časť odreže.

Porovnanie s Faster R-CNN R50-FPN (rovnaké dáta, rozdelenie a seedy) · AP podľa tried: data/per_class_ap_mean.csv

Patches aj crazing nad prahom



Ako čítať mapy

- Patches (0.93): všetky tri škvrny nad prahom 0.55; HiResCAM pre veľký box svieti na jeho koncoch a pri okraji
- Crazing (0.59): jeden box nad prahom, širší ako anotácie; HiResCAM sleduje línie trhlín vnútri boxu
- Faster R-CNN na tom istom crazing obrázku prahom 0.82 neprešiel (snímka 9)

Panely: anotácia · predikcie nad prahom · Grad-CAM · HiResCAM (biely box) · seed 42 · mapy: hybridný enkodér, 3 mierky · gradcam/2_rtdetrv2_s

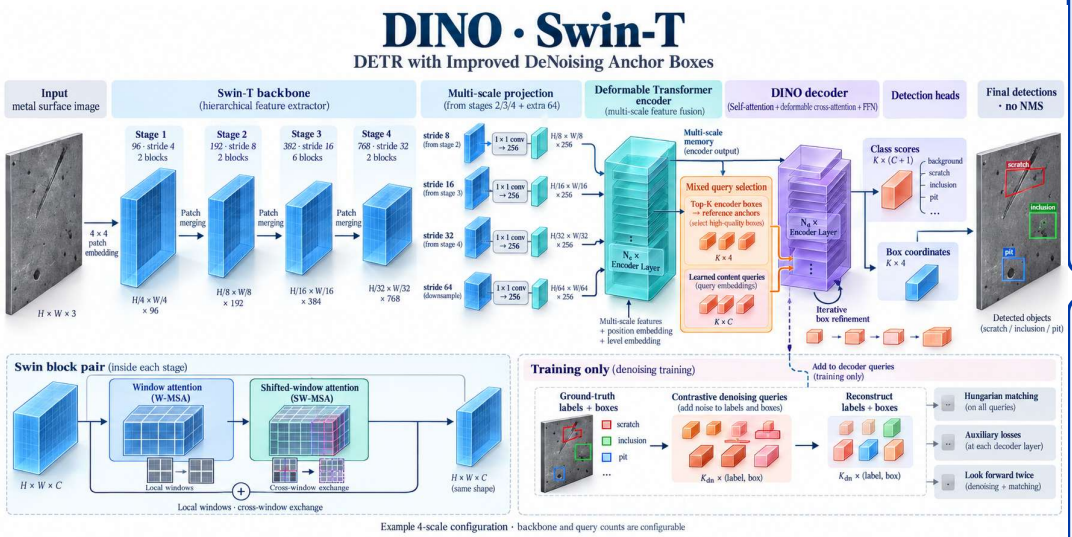
ĎALŠIE DETEKTORY · B / D

DETR S ODŠUMOVANÍM

DINO · Swin-T, 4 mierky, predtrénovaný na COCO (detrex)

B · DETR S ODŠUMOVANÍM — MYŠLIENKA

DINO: transformer od chrbtice až po boxy



Popis siete

- Swin-T: transformerová chrbtica s pozornosťou v posúvaných oknách
- Deformovateľný enkodér aj dekodér, 6 + 6 vrstiev, 4 mierky
- Odšumovanie: k dopytom sa pridajú zašumené GT boxy, ktoré sa model učí opraviť alebo zamietnuť
- Konfigurácia a COCO checkpoint z detrex (51.3 AP)

Očakávanie

- Najsilnejší COCO model v porovnaní (51.3 AP) → najvyššia presnosť
- Odšumovanie stabilizuje priraďovanie → rýchla konvergencia
- Vysoké rozlíšenie a 4 mierky by mali pomôcť malým a tenkým defektom
- Cena: najviac parametrov, pamäte a najvyššia latencia

configs/dino_swin_t_4scale.yaml · detrex projects/dino · Zhang et al., ICLR 2023

48 M parametrov, 900 dopytov, dávka 4

48.04 M

parametrov celkom (hlava NEU) — najväčší detektor

900

dopytov (RT-DETRv2, RF-DETR: 300)

17.3 GB

špičková pamäť GPU na NEU (referencia: 10 GB)

Hyperparameter	Nastavenie
Predtrénovanie	detrex DINO-Swin-T 4-scale, COCO 51.3 AP
Optimalizátor	AdamW, lr 2.5e-5 (1e-4 pri dávke 16, lineárne škálované)
Ďalšie	chrbtica lr ×0.1; weight decay 1e-4; orezanie gradientu 0.1
Dávka	4 (recept 16)
Epochy	max. 36; pokles LR po 91.7 % trénovania
Včasné zastavenie	patience 10 na val COCO AP
Vstup	tréning 480–800; test kratšia strana 800, max. 1333
Augmentácia	oficiálny recept detrex
Inferencia	skóre ≥ 0.001, max. 100 boxov, bez NMS

Rýchlosť učenia lineárne škálovaná na dávku 4 · AMP · seedy 17, 42, 73

B · DETR S ODŠUMOVANÍM — VÝSLEDKY TRÉNOVANIA

Najlepší na GC10, na Magnetic Tile za ostatnými DETR

Testovacia časť	AP	AP50	AP75	AR100	Recall@wp	F1@wp
NEU-DET	0.468 ± 0.010	0.759	0.508	0.715	0.677	0.730
GC10-DET	0.333 ± 0.008	0.634	0.311	0.587	0.585	0.670
Magnetic Tile	0.303 ± 0.008	0.498	0.301	0.646	0.324	0.453

Δ AP oproti Faster R-CNN
NEU +0.079 · GC10 +0.059 · MT +0.089

Čas trénovania
NEU 84 · GC10 79 · MT 62 min

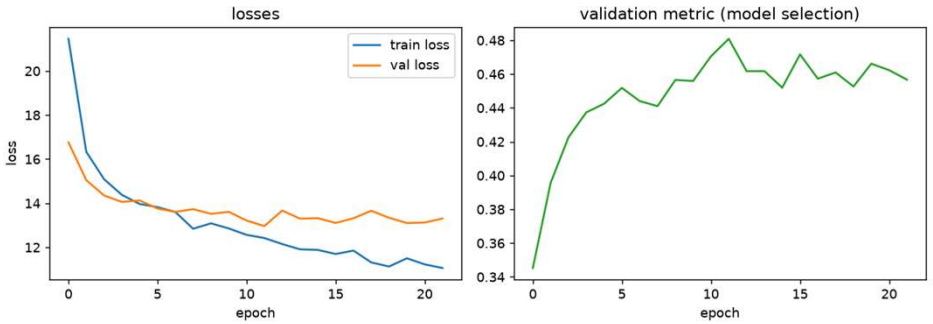
Latencia, medián end-to-end
NEU 85 · GC10 80 · MT 116 ms

Priemer ± smer. odch. cez seedy 17, 42, 73 · wp = pracovný bod pri IoU 0.5, prah skóre zvolený na validácii · boxy MT sú odvodené z masiek · RTX A6000, dávka 1

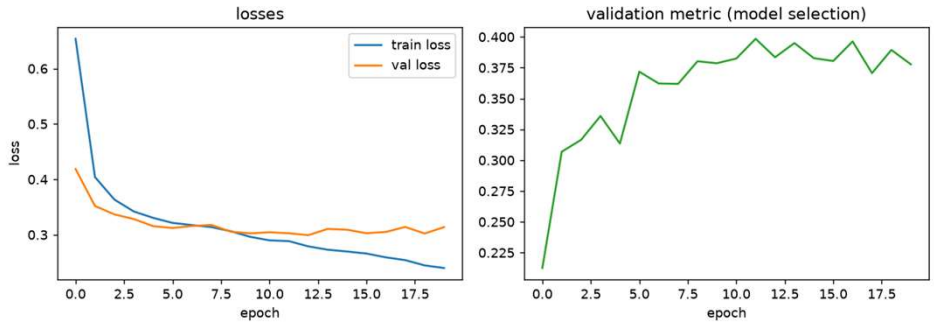
B · DETR S ODŠUMOVANÍM — KRIVKY TRÉNOVANIA

Vrchol už v epoche ~11, potom val strata stagnuje

DINO Swin-T



Faster R-CNN (referencia)



Val AP prudko stúpne a vrchol (~0.48) dosiahne okolo epochy 11; včasné zastavenie tréning ukončí okolo epochy 21. Tréningová strata ďalej klesá, validačná sa už nehýbe — veľký predtrénovaný model sa na 1224 trénovacích obrázkoch rýchlo prispôsobí a potom sa začne preučovať.

Seed 42, NEU-DET · validačná metrika = val COCO AP (výber modelu) · figures/per_model/3_dino_swin_t_4scale, 1_faster_rcnn_r50_fpn

B · DETR S ODŠUMOVANÍM — ČO BOLO LEPŠIE A PREČO

Najjemnejšie príznaky, najvyššia cena

Lepšie

- Najvyššie AP (0.333), AP50 a AR100 na GC10
- Najvyššie AP75 na NEU (0.508)
- MT: crack 0.07 → 0.41, blowhole 0.37 → 0.57 — najlepšie zo všetkých detektorov
- GC10: crease 0.11 → 0.30, oil spot 0.18 → 0.28

Horšie

- Latencia 80–116 ms: 3–7× viac ako RT-DETRv2 a RF-DETR
- Pamäť 17–23 GB, najdlhší tréning na NEU (84 min)
- MT: AP 0.303 pod ostatnými DETR; fray 0.10 vs 0.44–0.46
- AUROC obrázkov na MT 0.852 — najnižší

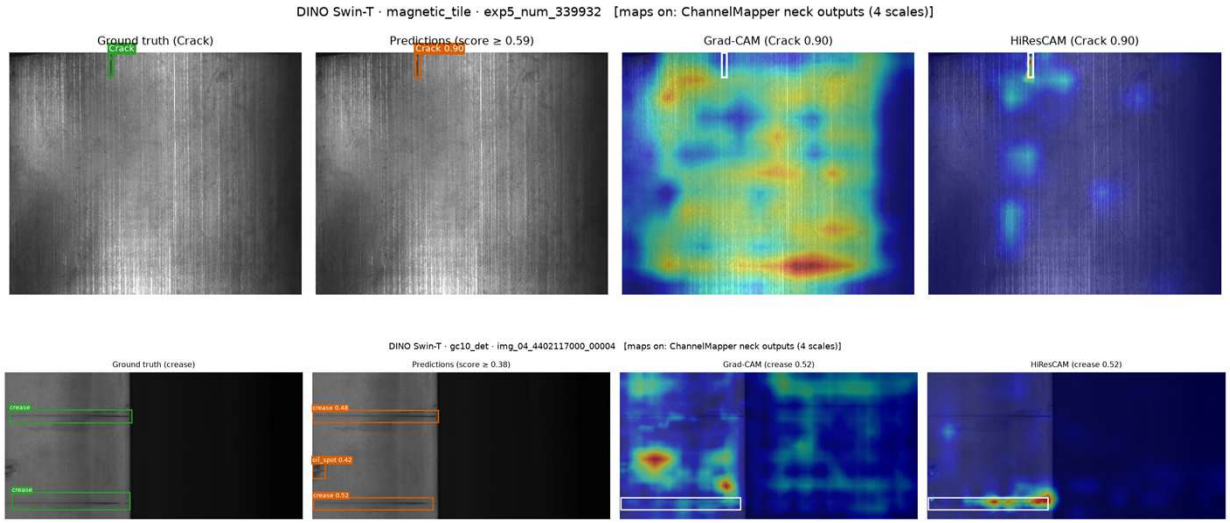
Pravdepodobne prečo (interpretácia)

Vstup až 1333 px, 4 mierky a 900 dopytov dávajú najjemnejšiu priestorovú informáciu — preto DINO vedie na tenkých trhlinách a malých bublinách. Na Magnetic Tile má len 268 chybných trénovacích obrázkov; veľký model sa rýchlo preučí a na triede fray zlyhá. Cenou za jemnosť je 6 + 6 vrstiev pozornosti na veľkých mapách.

Porovnanie s Faster R-CNN R50-FPN (rovnaké dáta, rozdelenie a seedy) · AP podľa tried: data/per_class_ap_mean.csv

B · DETR S ODŠUMOVANÍM — GRAD-CAM A HIRESCAM

DINO: trhlinu aj crease nájde, Grad-CAM sa rozleje



Ako čítať mapy

- Crack (0.90): najvyššie skóre na tejto trhline zo všetkých detektorov; HiResCAM v boxe, slabé škvrny aj inde
- Crease (0.52 a 0.48): obe línie nájdené; HiResCAM leží presne pozdĺž línie. Navyše falošný oil spot (0.42)
- Grad-CAM pokrýva takmer celú dlaždicu — priemer gradientu cez 4 mierky; pri DINO čítajte HiResCAM

Panely: anotácia · predikcie nad prahom · Grad-CAM · HiResCAM (biely box) · seed 42 · mapy: krk ChannelMapper, 4 mierky · gradcam/3_dino_swin_t_4scale

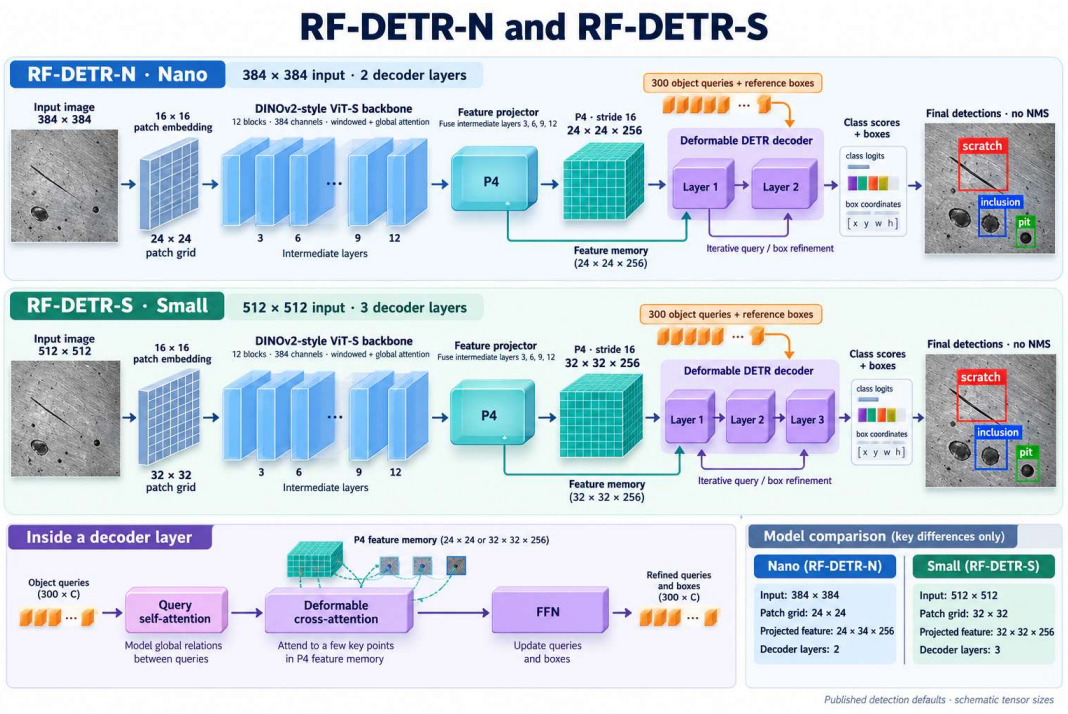
ĎALŠIE DETEKTORY · C / D

DETR S CHRBTICOU DINOV2

RF-DETR-N a RF-DETR-S · Roboflow, predtrénované na COCO

C · DETR S CHRBTICOU DINOV2 — MYŠLIENKA

RF-DETR: samoučiaca ViT chrbtica + ľahký DETR dekodér



Popis siete

- Chrbtica DINOv2 (ViT-S): transformer predtrénovaný samoučením
- Rozmery variantov nájdené vyhľadávaním architektúry (NAS) so zdieľanými váhami
- N a S majú rovnakú chrbticu; líšia sa rozlíšením (384 / 512) a počtom vrstiev dekodéra (2 / 3)
- Balík rfdetr 1.11.0, oficiálne COCO váhy variantov

Očakávanie

- Všeobecné príznaky DINOv2 by sa mali preniesť aj na textúry ocele a dlaždíc
- Ľahký dekodér → nízka latencia a malá pamäť
- Rýchla konvergencia vďaka silnému predtrénovaniu
- Otázka: stačí na jemné defekty rozlíšenie 384 / 512 px?

configs/_rfdetr_base.yaml, rfdetr_nano.yaml, rfdetr_small.yaml · Robinson et al., 2025

C · DETR S CHRBTICOU DINOV2 — PARAMETRE A HYPERPARAMETRE

~31 M parametrov, AdamW s EMA, efektívna dávka 16

31.81 M

parametrov RF-DETR-S (hlava NEU); RF-DETR-N 30.17 M

512 px

natívne rozlíšenie S; N 384 px

3.6 GB

špičková pamäť GPU S (NEU); N 2.7 GB

Hyperparameter	Nastavenie
Predtrénovanie	COCO checkpoint variantu (chrbtica destilovaná z DINOv2)
Optimalizátor	AdamW, lr 1e-4, lr enkodéra 1.5e-4, weight decay 1e-4
Dávka	4 × 4 akumulácie = 16
Epochy	max. 60, bez warmupu
Včasné zastavenie	patience 10
EMA váh	áno
Presnosť výpočtov	AMP
Augmentácia	predvolené nastavenie rfdetr
Inferencia	skóre ≥ 0.001, max. 100 boxov, bez NMS

Runy nelogovali počet parametrov — spočítané z modelov rfdetr 1.11.0, zhodné s checkpointmi · seedy 17, 42, 73

C · DETR S CHRBTICOU DINOV2 — VÝSLEDKY TRÉNOVANIA

RF-DETR-S: najlepší AP na NEU aj Magnetic Tile

Testovacia časť	AP	AP50	AP75	AR100	Recall@wp	F1@wp
NEU-DET · N	0.458 ± 0.009	0.748	0.502	0.722	0.639	0.712
NEU-DET · S	0.471 ± 0.006	0.768	0.506	0.717	0.707	0.737
GC10-DET · N	0.322 ± 0.015	0.608	0.322	0.545	0.620	0.670
GC10-DET · S	0.322 ± 0.011	0.626	0.294	0.543	0.637	0.689
Magnetic Tile · N	0.335 ± 0.011	0.580	0.326	0.574	0.411	0.503
Magnetic Tile · S	0.348 ± 0.027	0.568	0.359	0.597	0.362	0.505

Δ AP vs Faster R-CNN (NEU · GC10 · MT)
N: +0.070 · +0.048 · +0.120
S: +0.082 · +0.048 · +0.134

Čas trénovania (NEU · GC10 · MT)
N: 24 · 25 · 13 min
S: 41 · 23 · 23 min

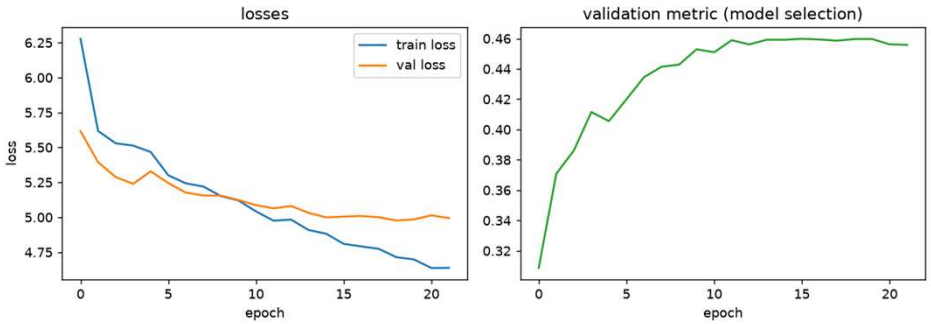
Latencia e2e, medián (NEU · GC10 · MT)
N: 22 · 36 · 16 ms
S: 24 · 30 · 28 ms

Priemer ± smer. odch. cez seedy 17, 42, 73 · wp = pracovný bod pri IoU 0.5, prah skóre zvolený na validácii · boxy MT sú odvodené z masiek · RTX A6000, dávka 1

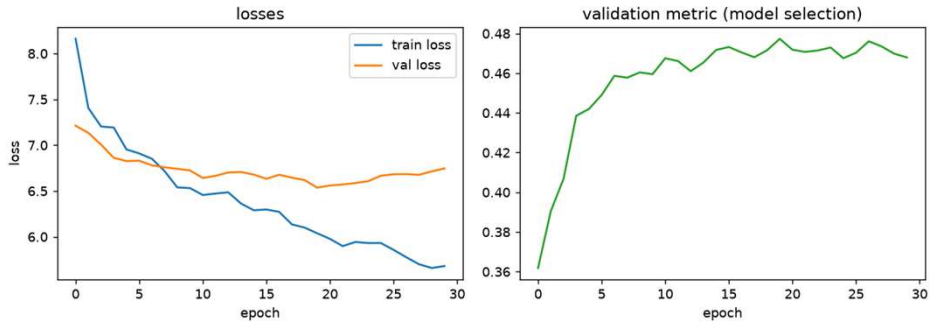
C · DETR S CHRBTICOU DINOV2 — KRIVKY TRÉNOVANIA

Plató za 10–20 epoch, tréning končí do 30 epoch

RF-DETR-N



RF-DETR-S



Oba varianty začínajú vysoko (val AP 0.31 / 0.36 po prvej epoche) a ustália sa po 10–20 epochách; včasné zastavenie ich ukončí okolo epochy 21 (N) a 29 (S) z max. 60. Pri S validačná strata od epochy ~18 mierne stúpa — začiatok preučenia, ktorý včasné zastavenie zachytí.

Seed 42, NEU-DET · validačná metrika = val COCO AP (výber modelu) · figures/per_model/4_rfdetr_nano, 5_rfdetr_small

C · DETR S CHRBTICOU DINOV2 — ČO BOLO LEPŠIE A PREČO

Najpresnejší a zároveň lacný na tréning

Lepšie

- RF-DETR-S: najlepšie AP na NEU (0.471) aj MT (0.348), AUROC obrázkov MT 0.961
- MT: AP +0.12 / +0.13 oproti Faster R-CNN; fray 0.12 → 0.44–0.46
- Najkratší tréning (13–41 min), pamäť len 2.7–3.6 GB
- NEU pitted surface 0.43 → 0.59 (S)

Horšie

- GC10: N aj S 0.322 — za DINO (0.333), v rámci rozptylu
- Väčší rozptyl seedov na GC10 a MT (± 0.011 až 0.027)
- Latencia 16–36 ms; na NEU a GC10 vyššia než RT-DETRv2
- N nie je o moc menší: 30.2 vs 31.8 M parametrov

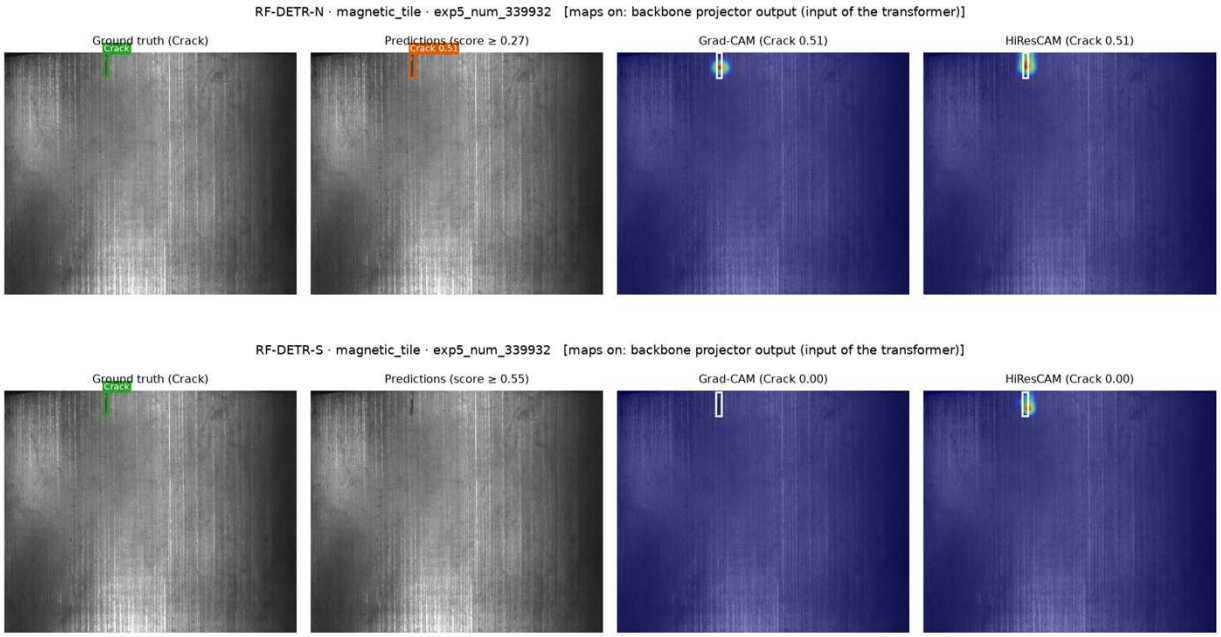
Pravdepodobne prečo (interpretácia)

Chrbtica DINOv2 sa učila samoučením na obrovskom množstve obrázkov, takže jej príznaky sú všeobecné a prenesú sa aj na kovové a keramické povrchy — model preto konverguje za 10–20 epoch. Väčšina parametrov je v chrbtici, ktorú majú N aj S spoločnú; rozdiel robí len rozlíšenie a hĺbka dekodéra.

Porovnanie s Faster R-CNN R50-FPN (rovnaké dáta, rozdelenie a seedy) · AP podľa tried: data/per_class_ap_mean.csv

C · DETR S CHRBTICOU DINOV2 — GRAD-CAM A HIRESCAM

Rovnaká trhlina: RF-DETR-N ju nájde, RF-DETR-S nie



Ako čítať mapy

- RF-DETR-N (0.51): box nad prahom 0.27; Grad-CAM aj HiResCAM sú len na trhline
- RF-DETR-S (0.004): žiadny box nad prahom 0.55, hoci HiResCAM stále sedí na trhline — pozerá sa správne, ale skóre je nízke
- Mapy na výstupe projektora (jedna mierka) sú veľmi kompaktné, bez rozliatia
- Sedí s metrikami: crack AP N 0.21 vs S 0.18

Panely: anotácia · predikcie nad prahom · Grad-CAM · HiResCAM (biely box) · seed 42 · mapy: projektor chrbtice · gradcam/4_rfdetr_nano, 5_rfdetr_small

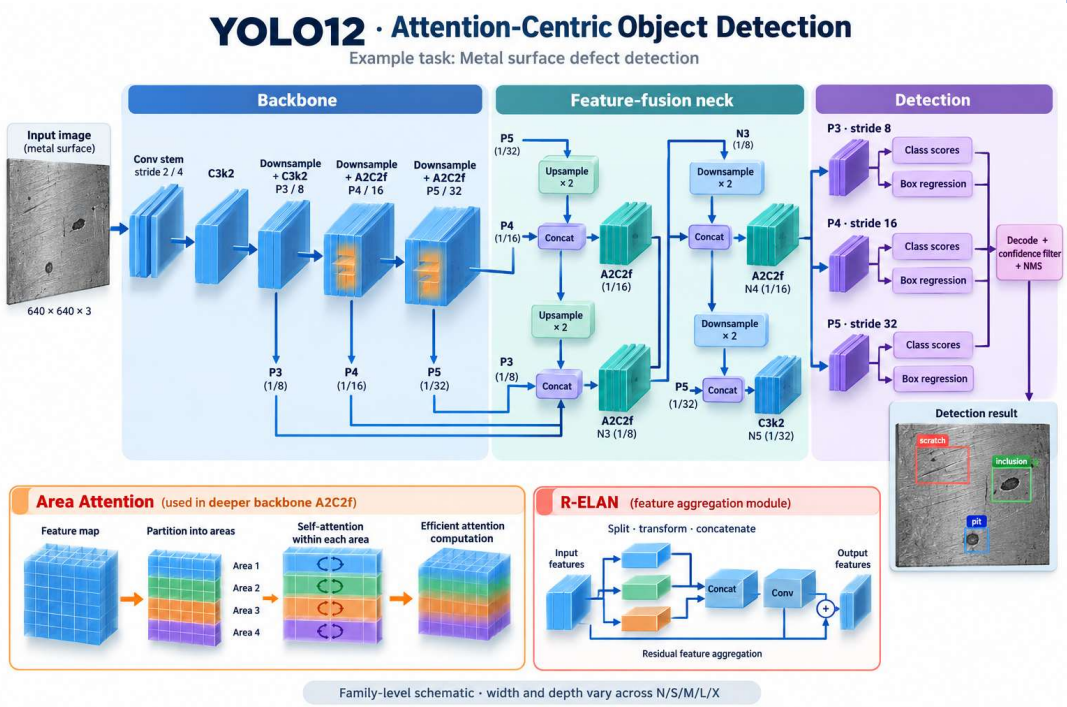
ĎALŠIE DETEKTORY · D / D

YOLO S POZORNOSŤOU

YOLO12-N a YOLO12-S · Ultralytics, predtrénované na COCO

D · YOLO S POZORNOSŤOU — MYŠLIENKA

YOLO12: jednostupňová CNN s oblastnou pozornosťou



Popis siete

- Jednostupňový detektor: každá bunka mapy priamo predikuje box a triedu
- Oblastná pozornosť delí mapu na 4 pásy a pozornosť počíta v každom zvlášť
- R-ELAN bloky stabilizujú tréning blokov s pozornosťou
- Ultralytics 8.4, COCO váhy v8.4.0, spoločný trénovač s ďalšími YOLO v projekte

Očakávanie

- Najmenší a najrýchlejší model v porovnaní
- Pozornosť by mala pridať kontext, ktorý čistej CNN chýba
- Recept ladený na COCO (mozaika) nemusí sedieť na defekty
- Ultralytics upozorňuje na možnú nestabilitu tréningu YOLO12

configs/_ultralytics_base.yaml, yolo12n.yaml, yolo12s.yaml · Tian et al., 2025

2.6 M a 9.3 M parametrov, 150 epoch s mozaikou

9.26 M

parametrov YOLO12-S (hlava NEU); YOLO12-N 2.57 M

640 px

letterbox; mozaika počas tréningu

5.5 GB

špičková pamäť GPU S (NEU); N 3.0 GB

Hyperparameter	Nastavenie
Predtrénovanie	oficiálne COCO váhy Ultralytics (v8.4.0)
Optimalizátor	optimizer=auto → AdamW, momentum 0.9
Rýchlosť učenia	0.002·5/(4+tried): NEU 0.001, GC10 0.000714, MT 0.001111
Dávka	16 (nominálna 64)
Epochy	max. 150; warmup 3 epochy; EMA váh
Včasné zastavenie	patience 30 na val fitness
Presnosť výpočtov	AMP
Augmentácia	mozaika (vypnutá posledných 10 epoch) + vertikálne preklopenie 0.5
Inferencia	skóre ≥ 0.001, max. 100 boxov, NMS IoU 0.7

Optimalizátor sa do runov nezapisuje — vyplýva z pravidla auto: AdamW, keď [N/64] × 150 < 10 000 iterácií · seedy 17, 42, 73

D · YOLO S POZORNOSŤOU — VÝSLEDKY TRÉNOVANIA

Na NEU mierne nad Faster R-CNN, na GC10 nie

Testovacia časť	AP	AP50	AP75	AR100	Recall@wp	F1@wp
NEU-DET · N	0.409 ± 0.008	0.732	0.401	0.628	0.642	0.705
NEU-DET · S	0.412 ± 0.009	0.734	0.406	0.635	0.667	0.709
GC10-DET · N	0.274 ± 0.005	0.576	0.223	0.449	0.584	0.648
GC10-DET · S	0.261 ± 0.009	0.551	0.217	0.450	0.544	0.625
Magnetic Tile · N	0.225 ± 0.016	0.395	0.211	0.326	0.314	0.420
Magnetic Tile · S	0.230 ± 0.029	0.368	0.236	0.363	0.338	0.442

Δ AP vs Faster R-CNN (NEU · GC10 · MT)
N: +0.020 · 0.000 · +0.011
S: +0.024 · −0.013 · +0.016

Čas trénovania (NEU · GC10 · MT)
N: 29 · 23 · 15 min
S: 46 · 32 · 20 min

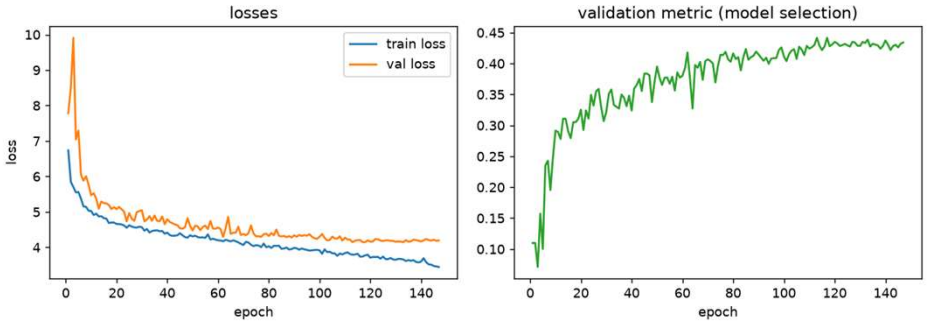
Latencia e2e, medián (NEU · GC10 · MT)
N: 25 · 19 · 13 ms
S: 20 · 21 · 12 ms

Priemer ± smer. odch. cez seedy 17, 42, 73 · wp = pracovný bod pri IoU 0.5, prah skóre zvolený na validácii · boxy MT sú odvodené z masiek · RTX A6000, dávka 1

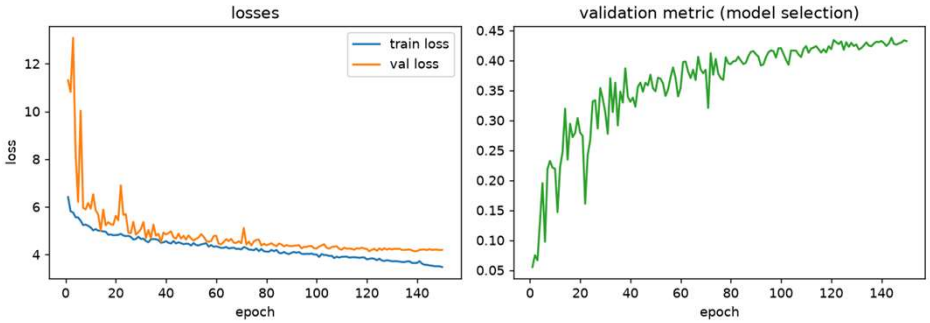
D · YOLO S POZORNOSŤOU — KRIVKY TRÉNOVANIA

Zašumený tréning, takmer celých 150 epoch

YOLO12-N



YOLO12-S



Val metrika oboch variantov skáče približne do epochy 70 a potom pomaly stúpa až do konca — tréning beží takmer celých 150 epoch a včasné zastavenie nezasiahne. Skoky v prvých epochách zodpovedajú upozorneniu Ultralytics na nestabilitu YOLO12. Posledných 10 epoch beží bez mozaiky.

Seed 42, NEU-DET · validačná metrika Ultralytics (fitness, výber modelu) · figures/per_model/6_yolo12n, 7_yolo12s

D · YOLO S POZORNOSŤOU — ČO BOLO LEPŠIE A PREČO

Malý a rýchly, presnosťou bližšie k CNN než k DETR

Lepšie

- 2.6 M (N) a 9.3 M (S) parametrov — 4–16× menej ako referencia
- Latencia 12–25 ms; na MT najrýchlejší (YOLO12-S 11.8 ms)
- NEU: AP +0.02; pitted surface 0.43 → 0.51–0.52
- Krátky tréning 15–46 min, pamäť 3.0–5.5 GB

Horšie

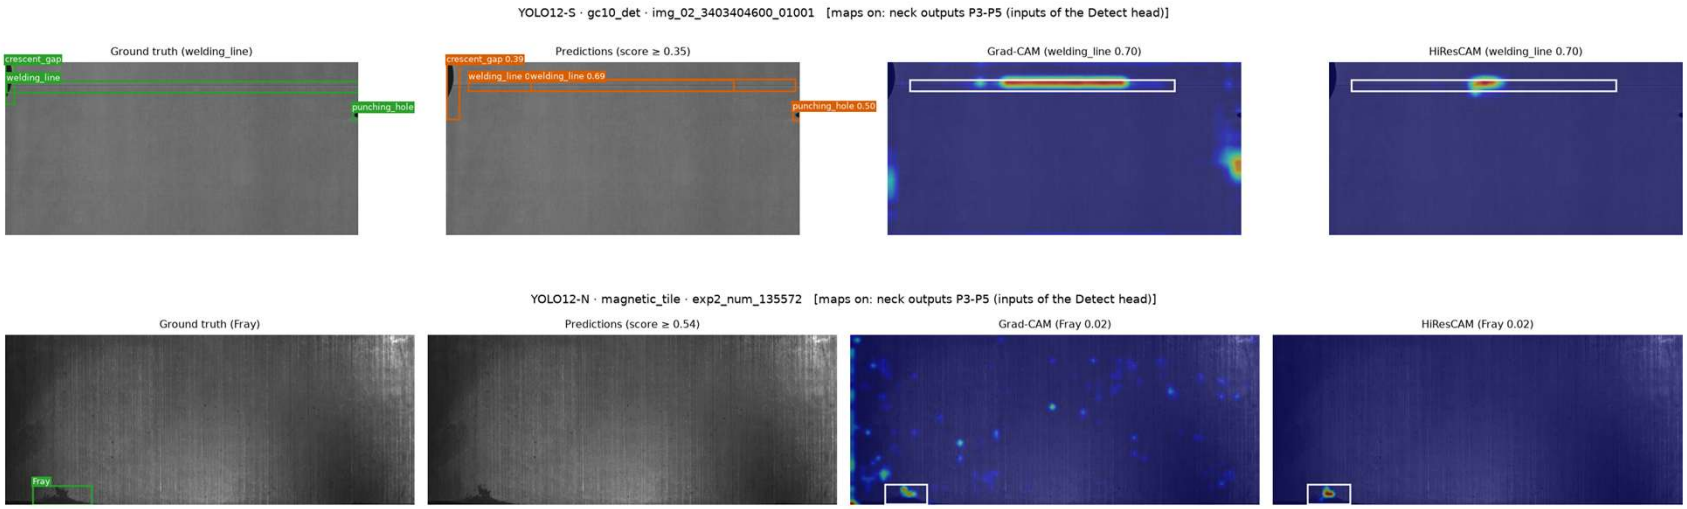
- O 0.05–0.12 AP pod DETR rodinou na každom datasete
- GC10 welding line 0.56 → 0.38 (N) / 0.26 (S); MT fray 0.12 → 0.01
- AP75 na NEU 0.40 — ďaleko od DETR (0.48–0.51)
- S nie je lepší ako N; na GC10 dokonca horší (0.261 vs 0.274)

Pravdepodobne prečo (interpretácia)

Pozornosť je v YOLO12 len lokálna (v pásoch) a výstupom sú husté predikcie čistené cez NMS — lokalizácia sa preto správa skôr ako pri CNN než pri DETR. Recept je ladený na COCO: mozaika skladá štyri zmenšené obrázky, čo pri pretiahnutých defektoch ako welding line a fray môže rozbiť ich tvar a kontext.

Porovnanie s Faster R-CNN R50-FPN (rovnaké dáta, rozdelenie a seedy) · AP podľa tried: data/per_class_ap_mean.csv

YOLO12: dlhý zvar rozdelí, fray takmer prehliadne



- Welding line (YOLO12-S, 0.70): zvar cez celú šírku predikuje niekoľkými kratšími boxmi namiesto jedného
- HiResCAM pokrýva len malú časť vysvetľovaného boxu — sedí s poklesom welding line 0.56 → 0.26 AP
- Fray (YOLO12-N, 0.02): žiadny box nad prahom 0.54; HiResCAM je na defekte, skóre však ďaleko pod prahom
- Tento kandidát nie je ani medzi 100 uloženými boxmi na obrázok (fray AP 0.01)

Panely: anotácia · predikcie nad prahom · Grad-CAM · HiResCAM (biely box) · seed 42 · mapy: krk P3–P5 · gradcam/7_yolo12s, 6_yolo12n

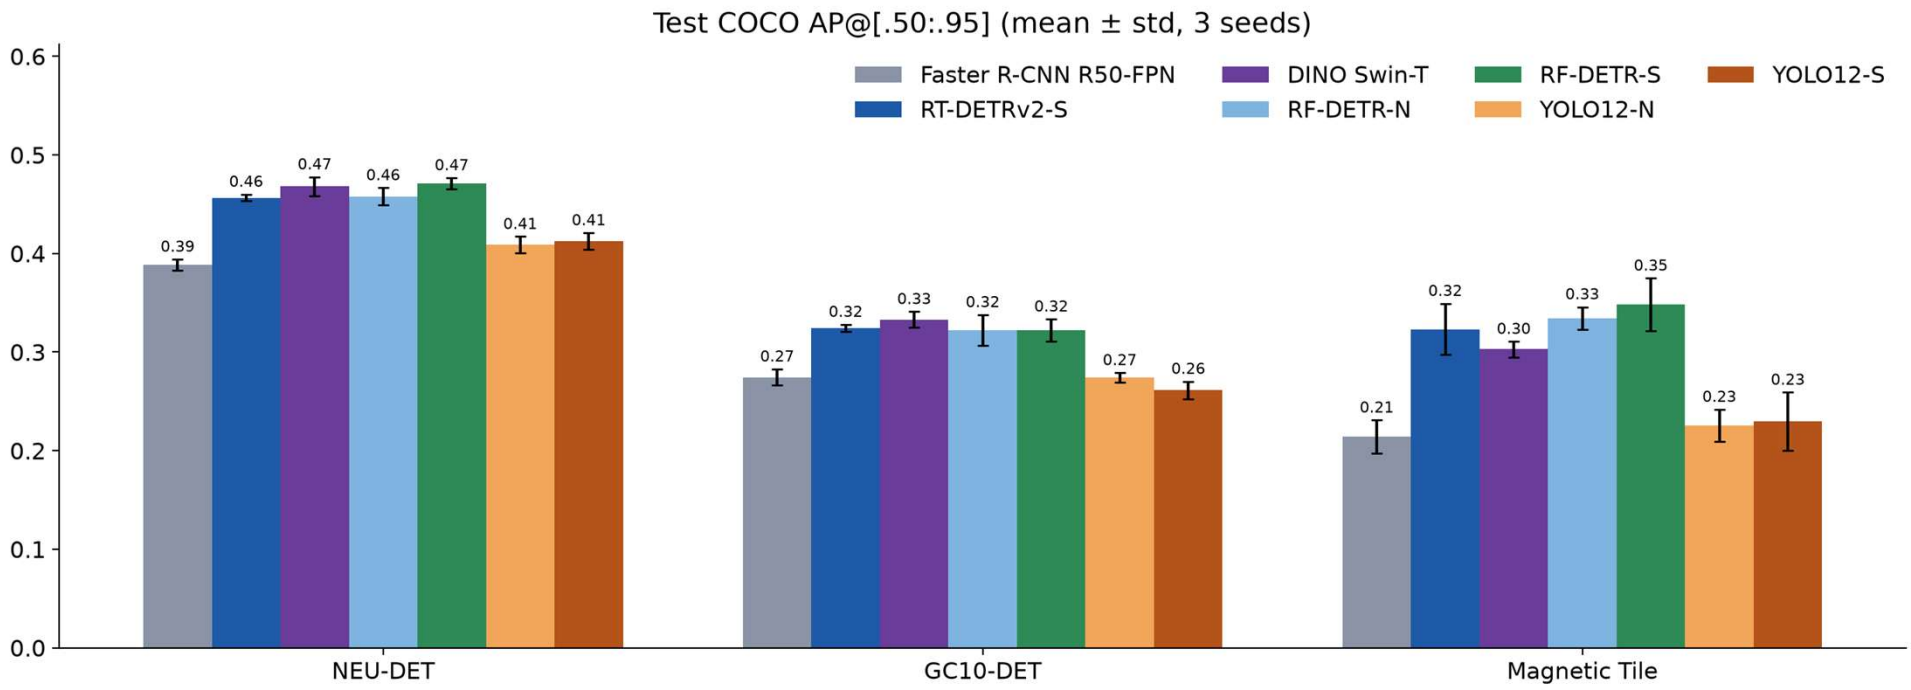
DETEKCIA · VŠETKY DETEKTORY

POROVNANIE DETEKTOROV

Faster R-CNN, RT-DETRv2, DINO, RF-DETR a YOLO12 na rovnakých dátach a seedoch

POROVNANIE DETEKTOROV — PRESNOSŤ

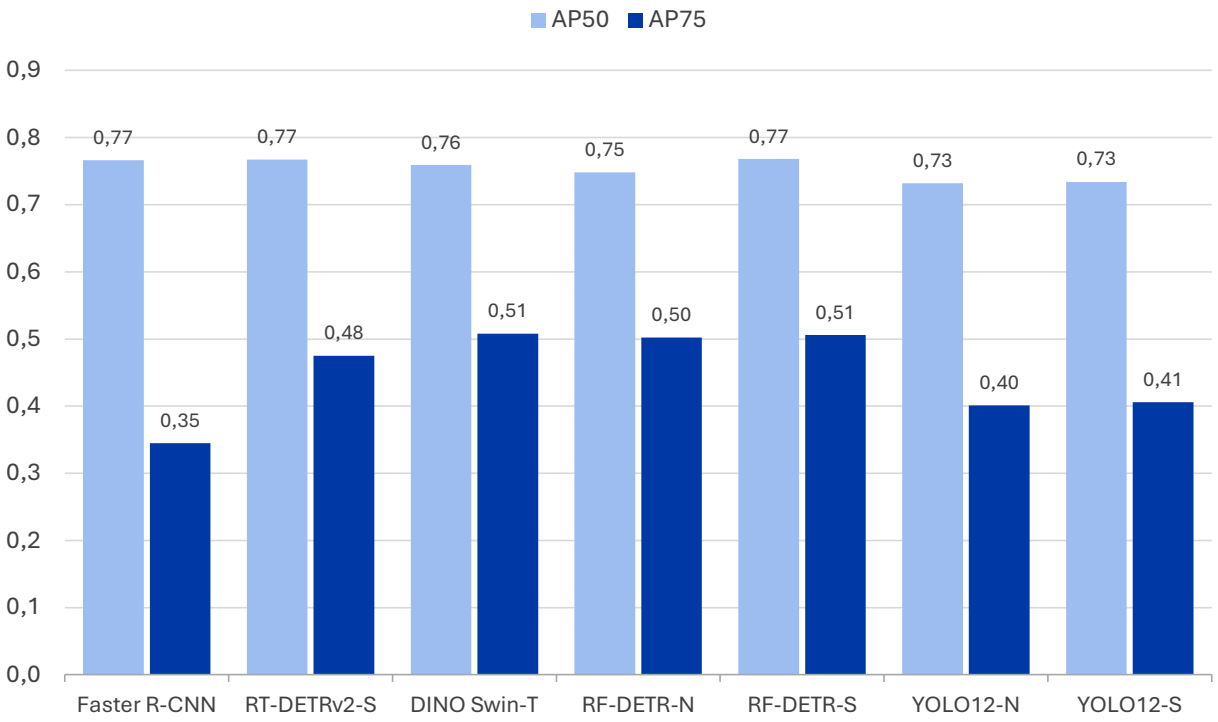
DETR rodina vedie na všetkých troch datasetoch



figures/comparison/AP_by_dataset.png · test, priemer ± smer. odch. cez seedy 17, 42, 73 · chybová úsečka = 1 smer. odch.

POROVNANIE DETEKTOROV — LOKALIZÁCIA

Zisk je v lokalizácii: AP50 rovnaké, AP75 vyššie



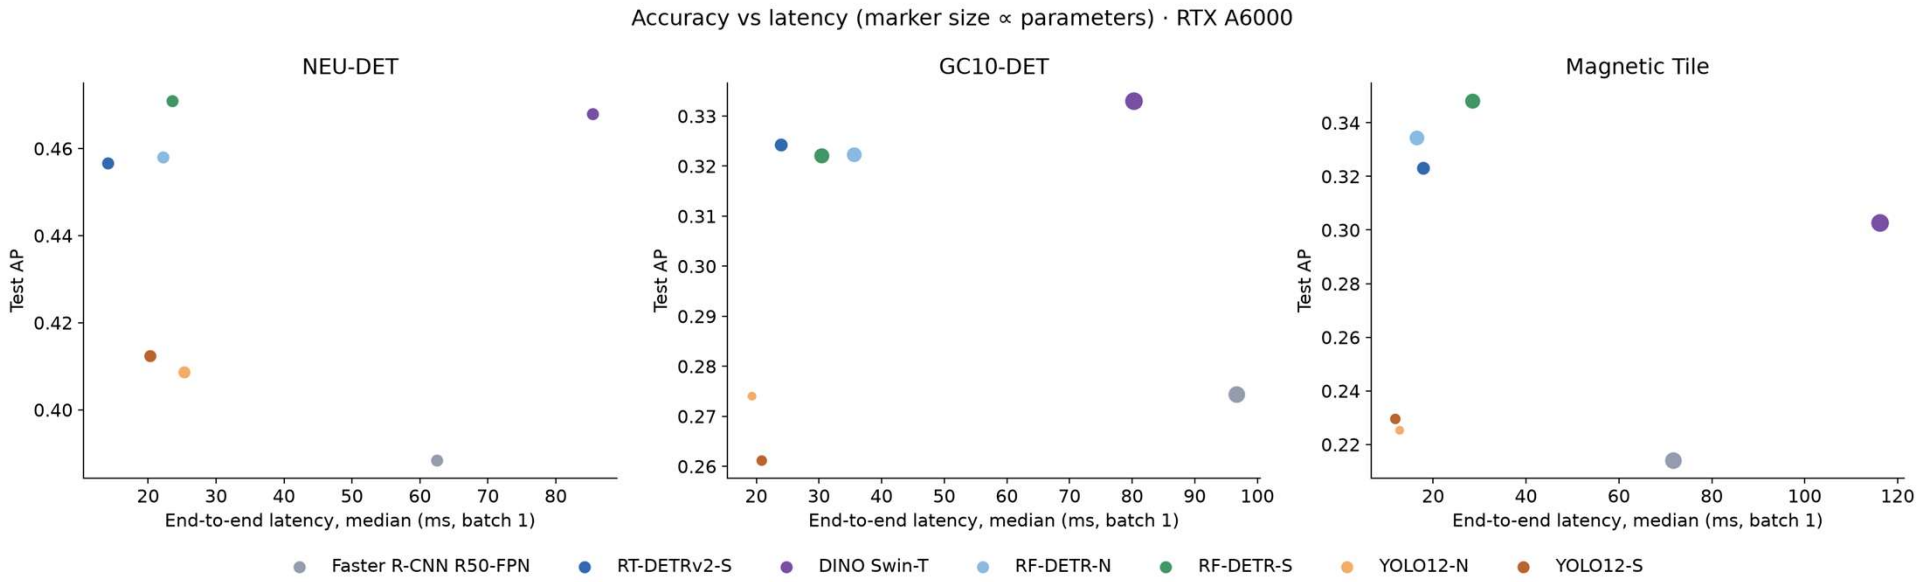
Ako čítať

- AP50 (box sa s anotáciou prekrýva aspoň z 50 %): všetci 0.73–0.77
- AP75 (prekryv aspoň 75 %): CNN referencia 0.35, YOLO12 0.40–0.41, DETR rodina 0.48–0.51
- Defekt nájdu všetky modely; DETR rodina ho ohraničí tesnejšie
- Na GC10 rovnaký obraz: AP75 0.22–0.25 (CNN, YOLO) vs 0.29–0.32 (DETR)

NEU-DET, test, priemer cez seedy 17, 42, 73 · data/results_summary_mean_std.csv

POROVNANIE DETEKTOROV — PRESNOSŤ VS. RÝCHLOSŤ

Presné aj rýchle: RT-DETRv2 a RF-DETR

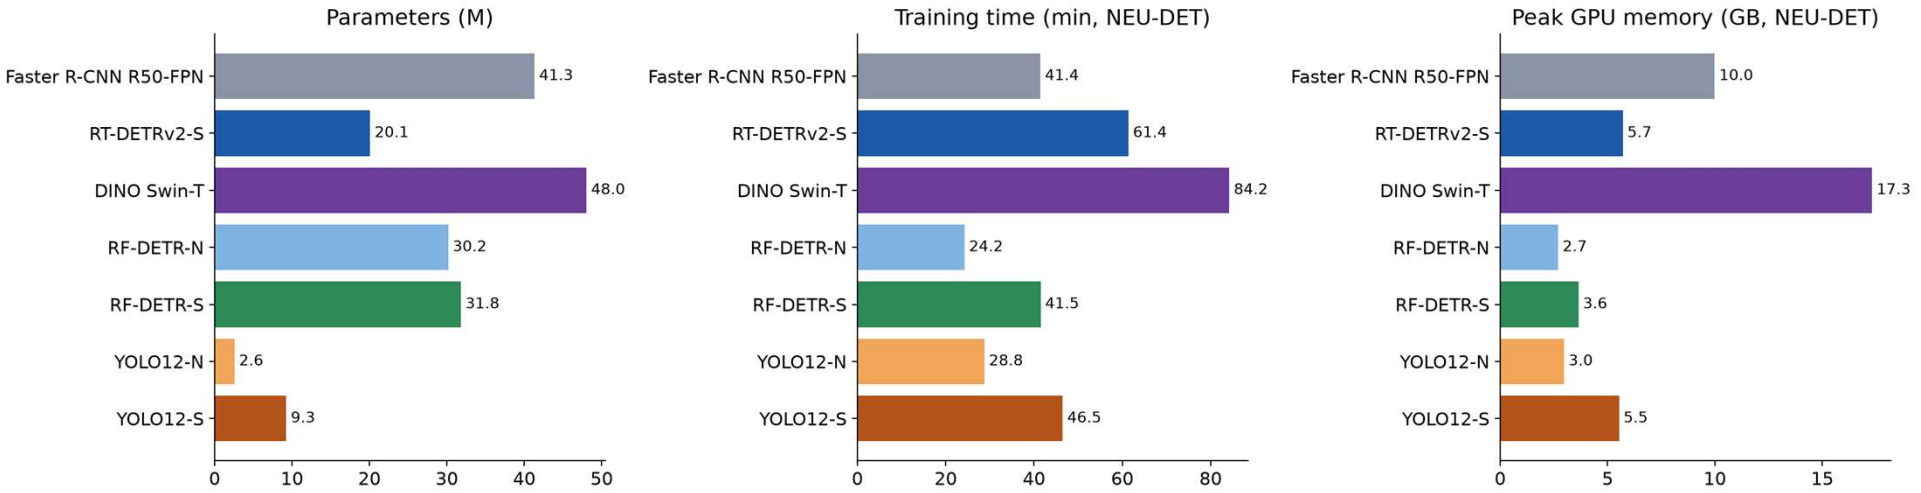


DINO je rovnako presný, ale pri 80–116 ms · Faster R-CNN je pomalší aj menej presný · YOLO12 je rýchly, ale o 0.05–0.12 AP nižšie

figures/comparison/AP_vs_latency.png · medián latencie end-to-end (načítanie + predspracovanie + model + postprocessing), dávka 1, fp32, RTX A6000

POROVNANIE DETEKTOROV — NÁKLADY

Náklady: od 2.7 GB (RF-DETR-N) po 17 GB (DINO)



Parametre

YOLO12-N 2.6 M → DINO 48.0 M

Čas trénovania, NEU

RF-DETR-N 24 min → DINO 84 min

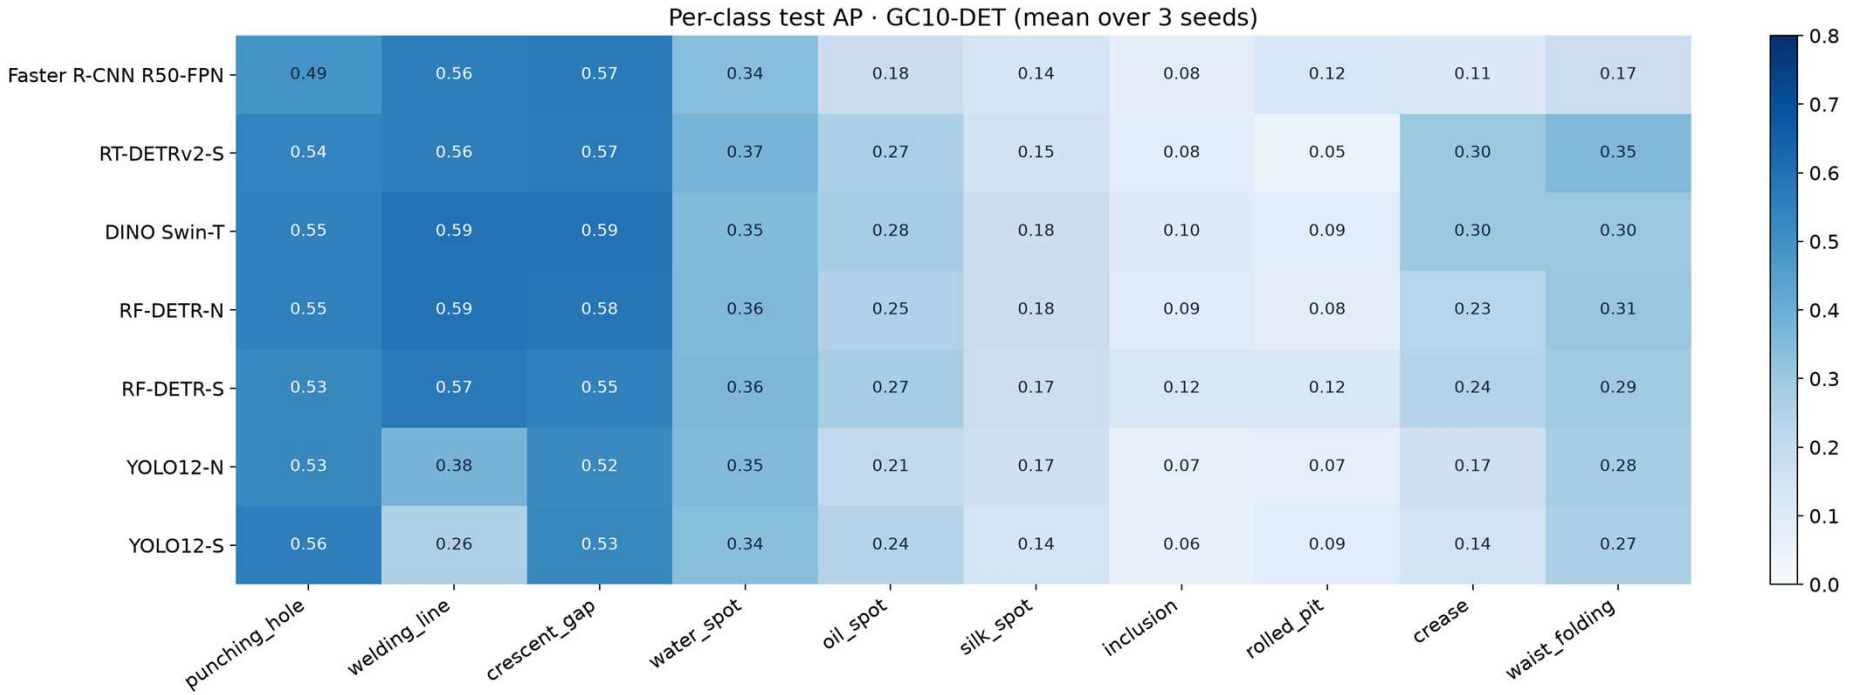
Špičková pamäť GPU, NEU

RF-DETR-N 2.7 GB → DINO 17.3 GB

figures/comparison/cost_params_time_memory.png · čas trénovania = priemer 3 seedov (wall-clock) · NEU-DET

POROVNANIE DETEKTOROV — AP PODĽA TRIED

GC10: zisk na crease, strata welding line pri YOLO12

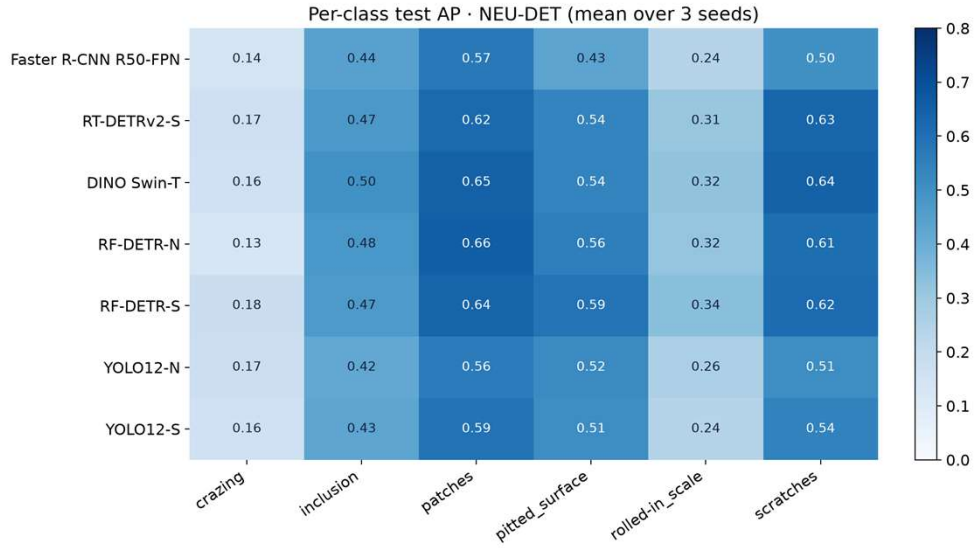


figures/comparison/per_class_AP_gc10_det.png · test, priemer cez seedy 17, 42, 73

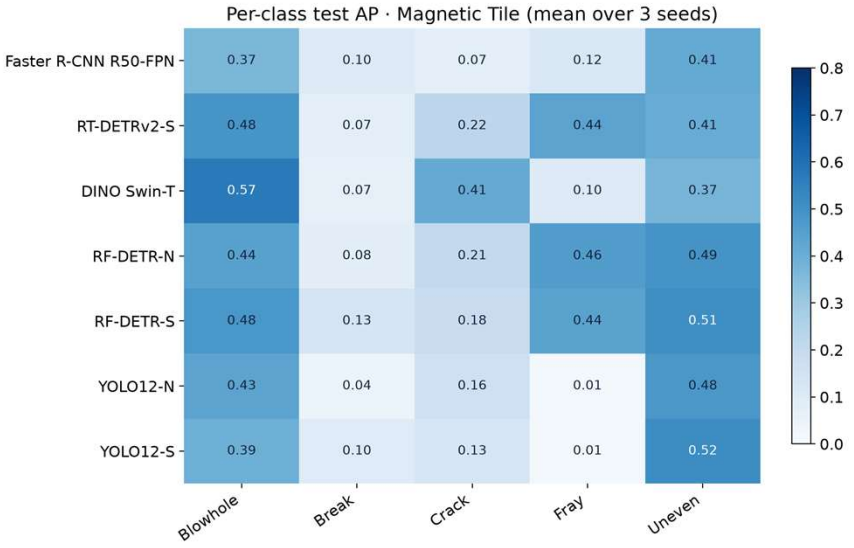
POROVNANIE DETEKTOROV — AP PODĽA TRIED

Ťažké triedy zostávajú ťažké — okrem trhlín pre DINO

NEU-DET



Magnetic Tile



Crazing pod 0.20 pri každom modeli · crack: DINO 0.41, ostatné 0.07–0.22 · fray: DETR 0.44–0.46 (okrem DINO 0.10), YOLO12 0.01

figures/comparison/per_class_AP_neu_det.png, per_class_AP_magnetic_tile.png · test, priemer cez 3 seedy

POROVNANIE DETEKTOROV — GRAD-CAM A HIRESCAM

Ako čítať mapy: pri detektoroch platí HiResCAM

Grad-CAM

- Každý kanál váži priemerným gradientom cez celú mapu
- Gradient detekcie prichádza len z jej boxu — priemer ho rozleje
- Štandardná metóda, preto ju ukazujeme

HiResCAM

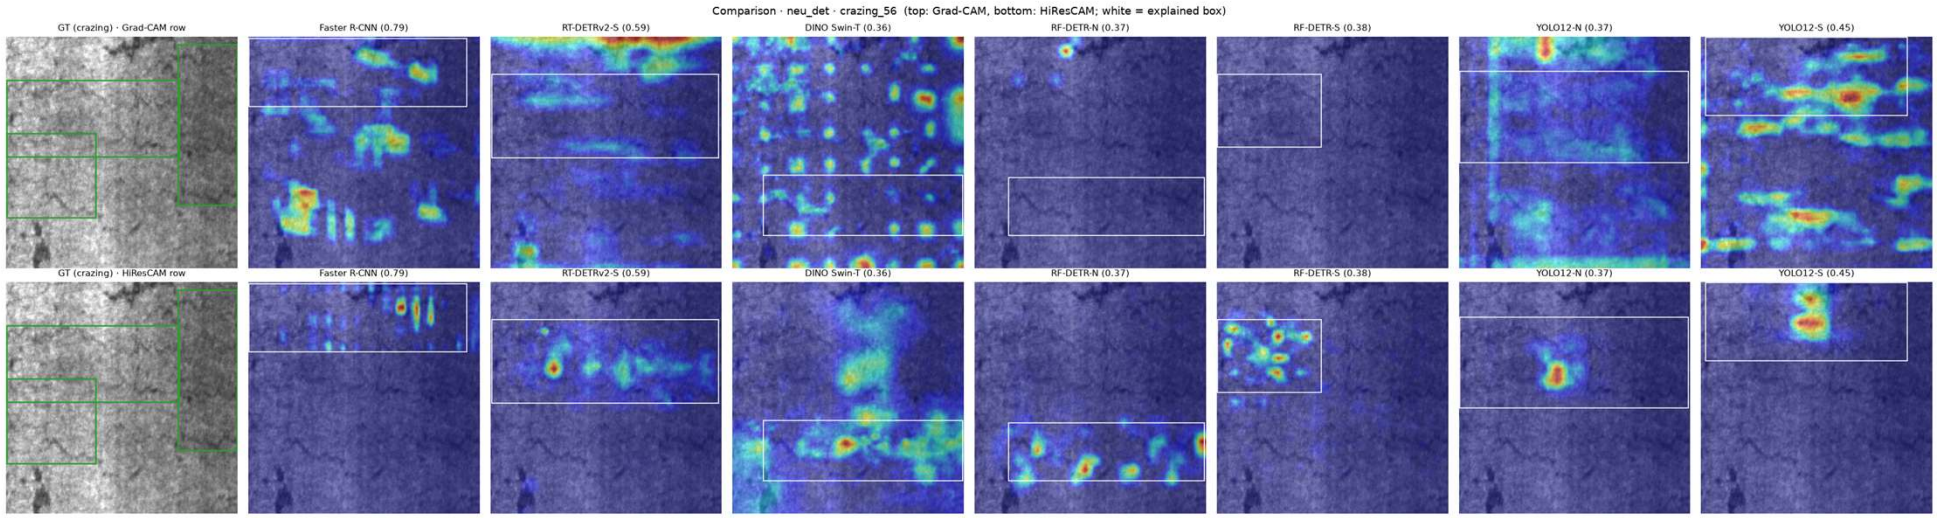
- Gradient × aktivácia v každom bode (Draelos & Carin, 2020)
- Ukazuje presne miesta, ktoré zvýšili skóre boxu
- Spoľahlivý panel pre detektory

Detektor	Mapy počítané na
Faster R-CNN (+ CBAM)	FPN P2–P5 — gradient dostane len úroveň, z ktorej bol RoI vybraný
RT-DETRv2-S	výstupy hybridného enkodéra, 3 mierky (kroky 8 / 16 / 32)
DINO Swin-T	výstupy krku ChannelMapper, 4 mierky
RF-DETR-N / S	výstup projektora chrbtice — jedna mierka, vstup transformera
YOLO12-N / S	výstupy krku P3–P5 (vstupy hlavy), bez letterbox okrajov

Rovnaké testovacie obrázky ako v časti 1–2 (typický obrázok každej triedy) · seed 42 · 150 zo 154 vysvetľovaných detekcií sedí s uloženým skóre do 0.02 · gradcam/README.md

POROVNANIE DETEKTOROV — GRAD-CAM A HIRESCAM

Crazing: siedmi detektori, sedem rôznych boxov

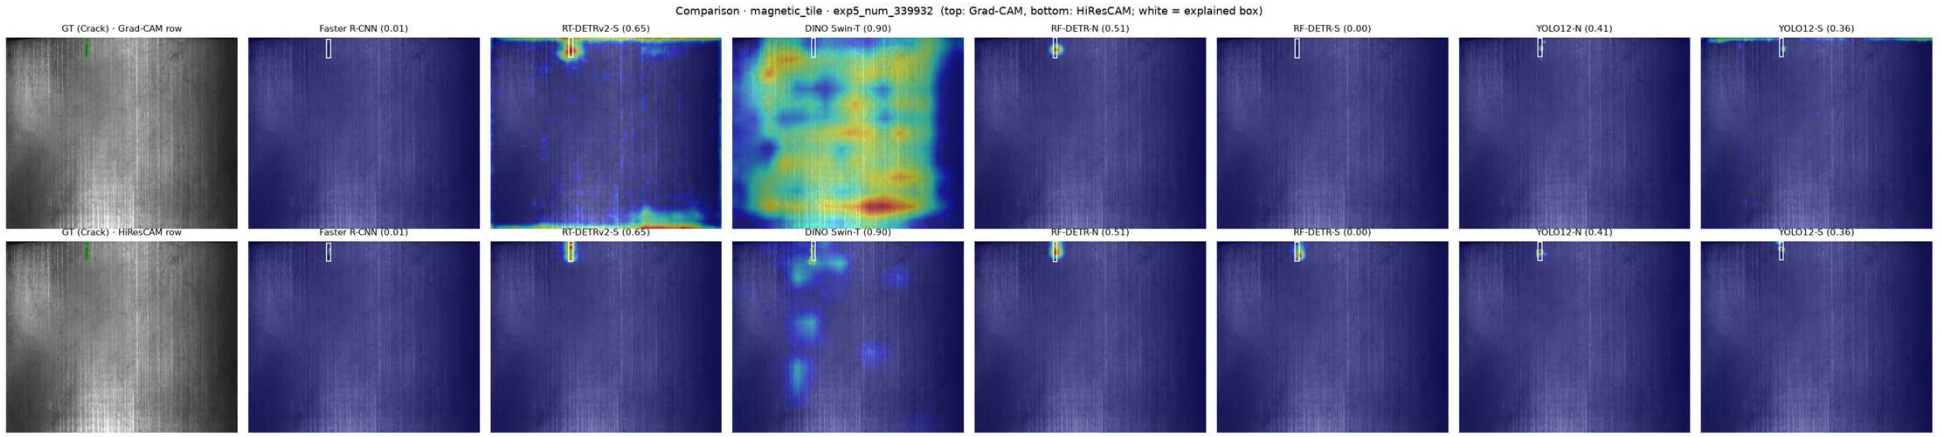


- Faster R-CNN, RT-DETRv2, RF-DETR: HiResCAM sleduje línie trhlín vo vlastnom boxe
- DINO: odozva presahuje box; Grad-CAM tvorí pravidelnú mriežku bodov
- YOLO12: kompaktná škvrna v boxe, nie pozdĺž trhlín
- Skóre 0.36–0.79: crazing je pre všetkých najťažšia trieda NEU (AP pod 0.20)

Horný riadok Grad-CAM, dolný HiResCAM · v zátvorke skóre vysvetľovaného boxu · seed 42 · gradcam/comparison/neu_det/crazing_crazing_56.png

POROVNANIE DETEKTOROV — GRAD-CAM A HIRESCAM

Tenká trhlina: Faster R-CNN ju nevidí, DETR áno



- Faster R-CNN (0.01): žiadna viditeľná odozva — trhlinu nezachytí (crack AP 0.07)
- DINO (0.90): najvyššie skóre; HiResCAM na trhline, Grad-CAM po celej dlaždici
- RT-DETRv2 (0.65), RF-DETR-N (0.51), YOLO12 (0.41 / 0.36): HiResCAM presne na trhline
- RF-DETR-S (0.00): pozerá sa na trhlinu, ale box nevytvorí

Horný riadok Grad-CAM, dolný HiResCAM · v zátvorke skóre triedy Crack · seed 42 · gradcam/comparison/magnetic_tile/Crack_exp5_num_339932.png

POROVNANIE DETEKTOROV — ZHRNUTIE

Všetky detektory vedľa seba

Detektor	Parametre	AP NEU	AP GC10	AP MT	AP75 NEU	ms NEU	Tréning NEU
1 · Faster R-CNN R50-FPN	41.3 M	0.388	0.274	0.214	0.345	62	41 min
2 · + CBAM	41.4 M	0.412	0.284	0.209	0.384	65	60 min
A · RT-DETRv2-S	20.1 M	0.457	0.324	0.323	0.475	**14**	61 min
B · DINO Swin-T	48.0 M	0.468	**0.333**	0.303	**0.508**	85	84 min
C · RF-DETR-N	30.2 M	0.458	0.322	0.335	0.502	22	**24 min**
C · RF-DETR-S	31.8 M	**0.471**	0.322	**0.348**	0.506	24	41 min
D · YOLO12-N	**2.6 M**	0.409	0.274	0.225	0.401	25	29 min
D · YOLO12-S	9.3 M	0.412	0.261	0.230	0.406	20	46 min

Prvá štvorica (A, B, C) je na NEU a GC10 v rámci ~1 smer. odch. — remíza. Na MT vedú RF-DETR (0.335–0.348) a RT-DETRv2 (0.323); CBAM a YOLO12 sú na MT s Faster R-CNN v rámci rozptylu.

Tučné = najlepšie v stĺpci · priemer z 3 seedov · ms = medián latencie end-to-end, dávka 1, RTX A6000 · riadok CBAM z časti 2

POROVNANIE DETEKTOROV — ZÁVERY

Čo priniesol každý detektor

RT-DETRv2-S

Takmer najvyššia presnosť pri najnižšej latencii na NEU (14 ms) a 20 M parametroch. Na MT nízky recall v pracovnom bode.

DINO Swin-T

Najlepší na GC10 a na tenkých trhlinách (crack 0.41), ale 3–7× pomalší a 17–23 GB pamäte.

RF-DETR-N / S

Najlepší AP na NEU a MT (S), najlacnejší tréning (13–41 min, pamäť do 3.6 GB). N ≈ S.

YOLO12-N / S

Najmenší (2.6 M) a rýchly, no presnosť zostáva na úrovni CNN referencie; S neprekoná N.

Odporúčanie: RF-DETR-S ako predvolený detektor defektov; RT-DETRv2-S, keď rozhoduje latencia; DINO len vtedy, keď záleží na tenkých trhlinách a GPU to unesie.

Rozdiely v prvej štvorici sú na NEU a GC10 približne v rámci jednej smer. odch. (n = 3 seedy) · zdroj: data/results_summary_mean_std.csv

Zdroje — ZHRNUTIE

Všetky detektory vedľa seba

Faster R-CNN GitHub - pytorch/vision: Datasets, Transforms and Models specific to Computer Vision
Yolo10-26 GitHub - ultralytics/ultralytics: Ultralytics YOLO27, YOLO26, YOLO11, YOLOv8 — object detection, ins...
RF-DETR N/S https://github.com/roboflow/rf-detr
RT-DETRv2-S https://github.com/lyuwenyu/RT-DETR
D-FINE-S https://github.com/Peterande/D-FINE
DINO Swin-T https://github.com/IDEA-Research/detrex
ViTDet-B https://github.com/facebookresearch/detectron2
R-CNN Swin-T https://github.com/open-mmlab/mmdetection
Attention U-Net https://github.com/Project-MONAI/MONAI
TransUNet https://github.com/Beckschen/TransUNet

STU FEI
SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

ĎAKUJEM ZA POZORNOSŤ

Otázky a diskusia

